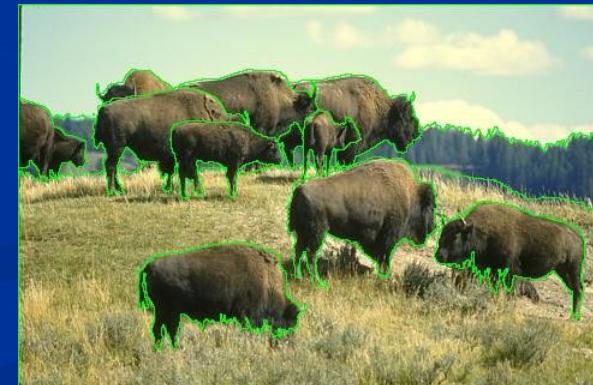
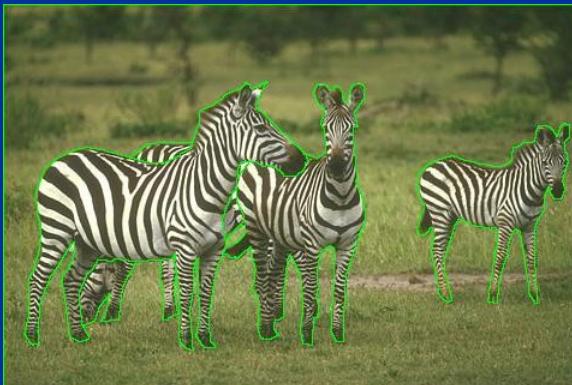


# **Segmentácie obrazu**

**Šonka, Hlaváč, Boyle: Image processing, Analysis and Machine Vision** kapitola: Segmentation  
**Richard Szeliski: Computer Vision: Algorithms and Applications**  
kapitola: Segmentation

# Segmentácia obrazu

- Hlavným cieľom segmentácie je rozdeliť obraz na časti, ktoré majú silnú koreláciu s objektmi alebo oblastami reálneho sveta zobrazenými v obraze.



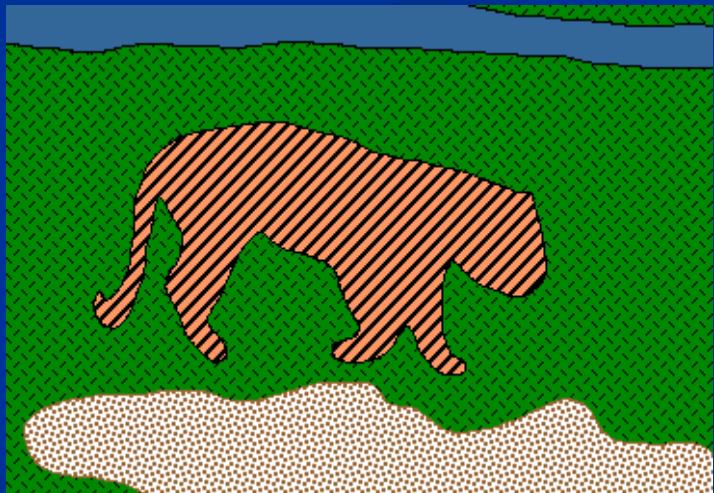
# Úplná vs. čiastočná segmentácia

- Pri čiastočnej segmentácii je cieľom rozdeliť obraz na časti, ktoré sú homogénne z hľadiska vybranej vlastnosti, napr. jasu, farby, odrazivosti, textúry apod.



# Úplná vs. čiastočná segmentácia

- Úplná segmentácia - rozdelenie obrazu na disjunktné oblasti, ktoré zodpovedajú objektom reálneho sveta

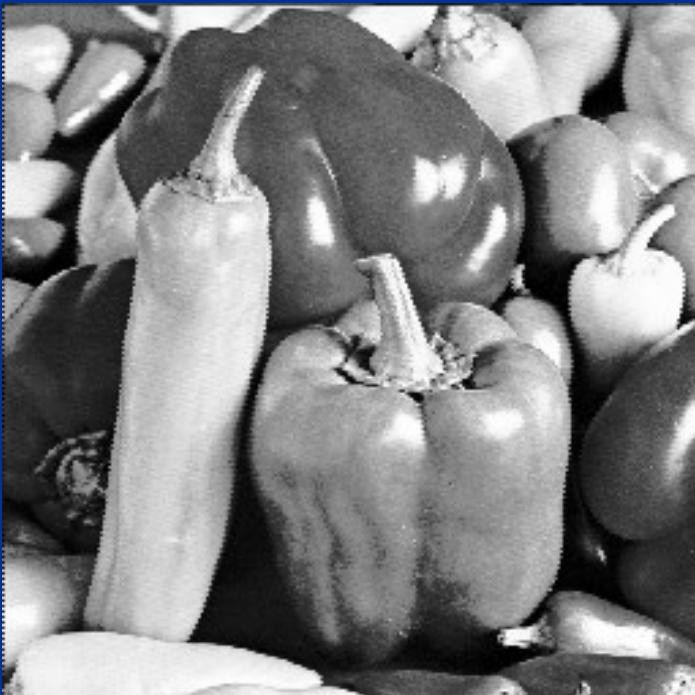


- Každá oblasť môže byť reprezentovaná uzavretou hranicou a každá uzavretá hranica popisuje oblasť.
- Nejednoznačnosť obrazových dát je hlavným segmentačným problémom, často sprevádzaným informačným šumom.
- Čím viac apriórnej informácie je k dispozícii pri segmentačnom procese, tým lepšie výsledky pri segmentácii možno dosiahnuť.

- Segmentácia môže byť na základe
  - úrovní šedej,
  - farby,
  - textúry,
  - hĺbky alebo
  - pohybu.

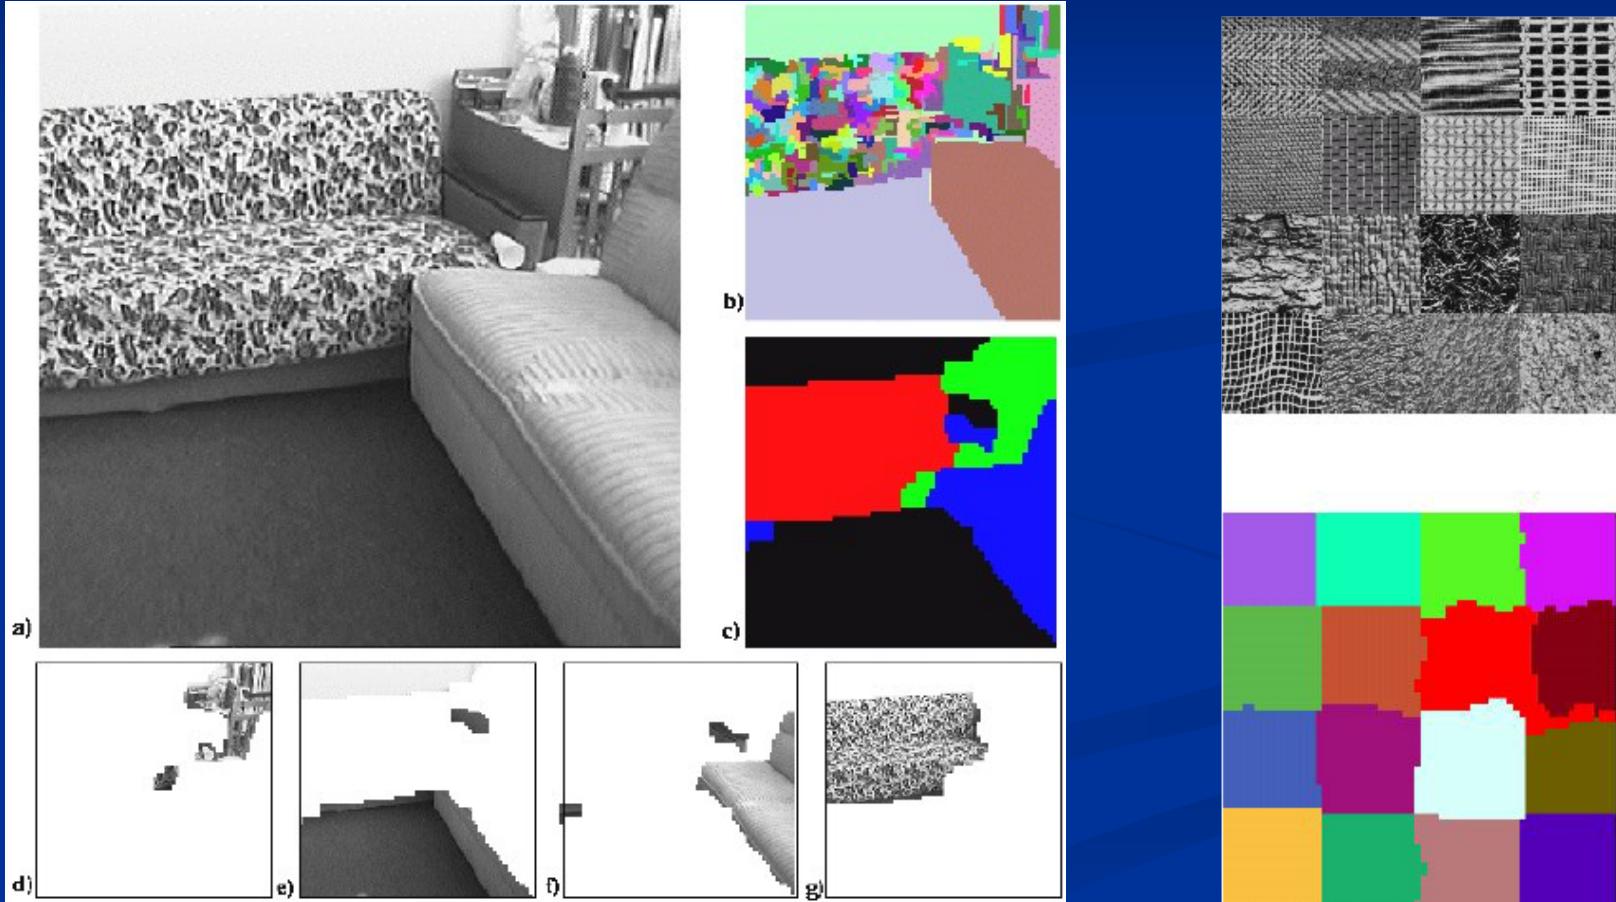
# Segmentácia na základe úrovní šedej

- Jednoduchá metóda môže viest' k nepresnostiam v segmentácii



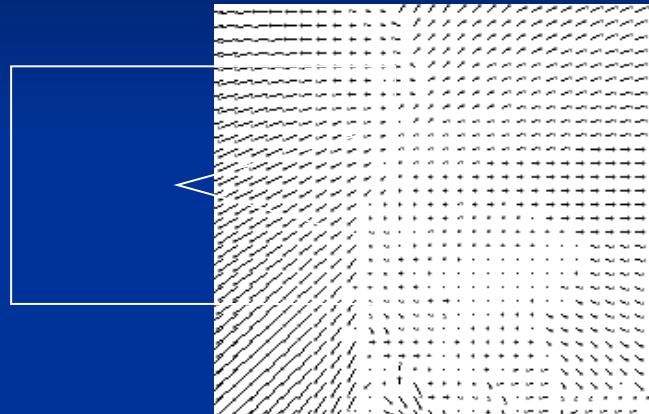
# Segmentácia na základe textúry

- Umožňuje segmentovať povrhy objektov z rôznou textúrou



# Segmentácia na základe pohybu

- Je potrebný medzikrok – vypočítať *optical flow field*



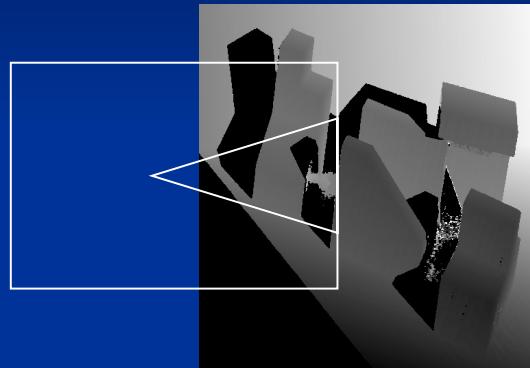
# Segmentácia na základe hĺbky

- Užitočné pri mobilných robotoch

Original  
image



Range  
image



Segmented  
image



# Image segmentation

Potrebujeme definovať a implementovať kritéria podobnosti

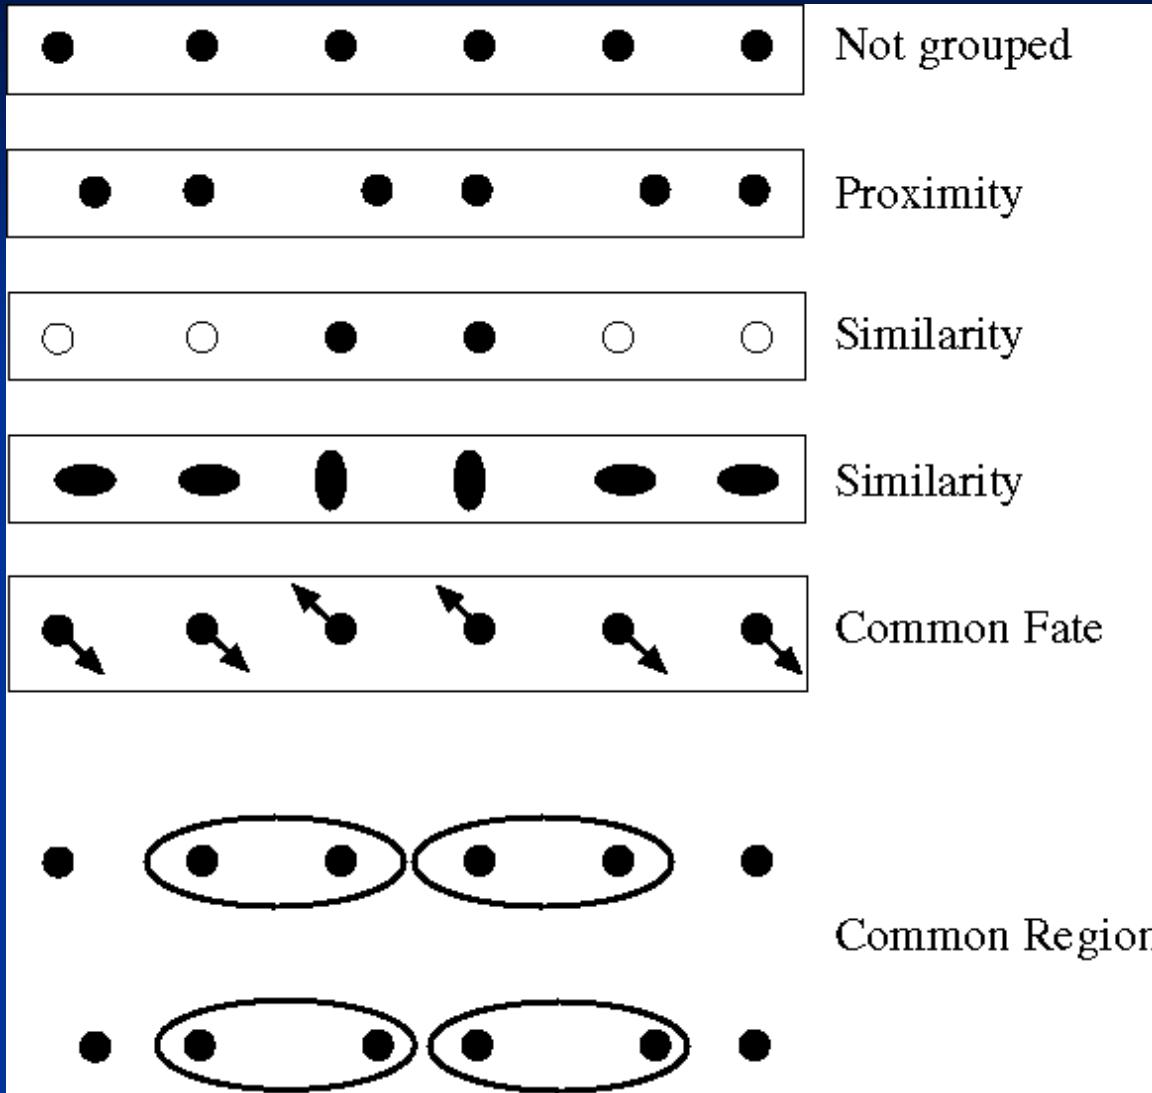
- Ale čo chceme aby bolo v každom regióne podobné?
- Existuje nejaká vlastnosť, ktorá spôsobí, že región bude zmysluplný objekt ?

# Gestalt laws

A series of factors affect whether elements should be grouped together.

- Proximity: tokens that are nearby tend to be grouped.
- Similarity: similar tokens tend to be grouped together.
- Common fate: tokens that have coherent motion tend to be grouped together.
- Common region: tokens that lie inside the same closed region tend to be grouped together.
- Parallelism: parallel curves or tokens tend to be grouped together.

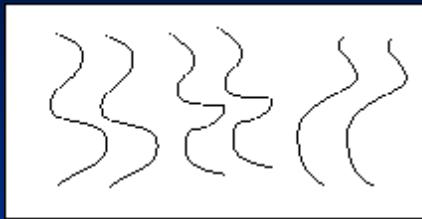
# Gestalt laws



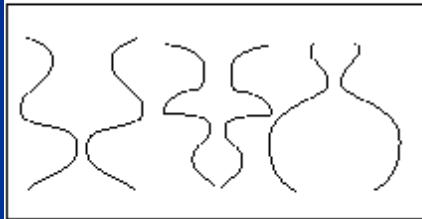
# Gestalt laws

- Closure: tokens or curves that tend to lead to closed curves tend to be grouped together.
- Symmetry: curves that lead to symmetric groups are grouped together.
- Continuity: tokens that lead to “continuous” curves tend to be grouped.
- Familiar configuration: tokens that, when grouped, lead to a familiar object, tend to be grouped together.

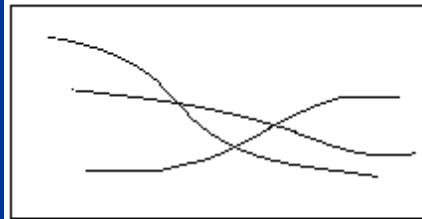
# Gestalt laws



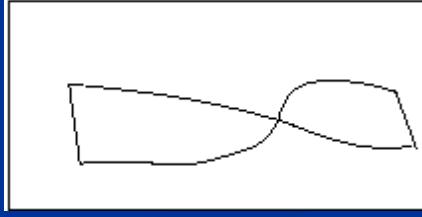
Parallelism



Symmetry



Continuity



Closure

# Segmentačné kritéria

- Segmentácia je rozdelenie obrazu I na množinu regiónov  $S_i$ , ktoré spĺňajú nasledujúce kritéria :

1.  $\cup S_i = S$   
obraz

2.  $S_i \cap S_j = \emptyset$ ,  $i \neq j$   
neprekryvajú

3.  $\forall S_i, P(S_i) = \text{true}$   
pre

4.  $P(S_i \cup S_j) = \text{false}$ ,  
regiónov  
 $i \neq j$ ,  $S_i$  adjacent  $S_j$

Rozdelenie pokrýva celý

Žiadne regióny sa

Homogenita je splnená  
každý región

Zjednotenie susedných  
nesplňa kritéria.

# Segmentačné metódy

Pixel-based

- Histogram
- Clustering

Edge-based

Region-based

- Region growing
- Split and merge

Model-based

Physics-based

Graph-based

# Thresholding, modifications

**Local adaptive thresholds**, rozdelí obraz na podobrazy a určí threshold pre každý z nich

**Band thresholding**, nech  $D$  je množina intenzít

$$g(i, j) = \begin{cases} 1 & \text{for } f(i, j) \in D, \\ 0 & \text{otherwise.} \end{cases}$$

**Multiple thresholds.**

**Semi-thresholding**, potláča pozadie, užitočné ak obraz je analyzovaný človekom

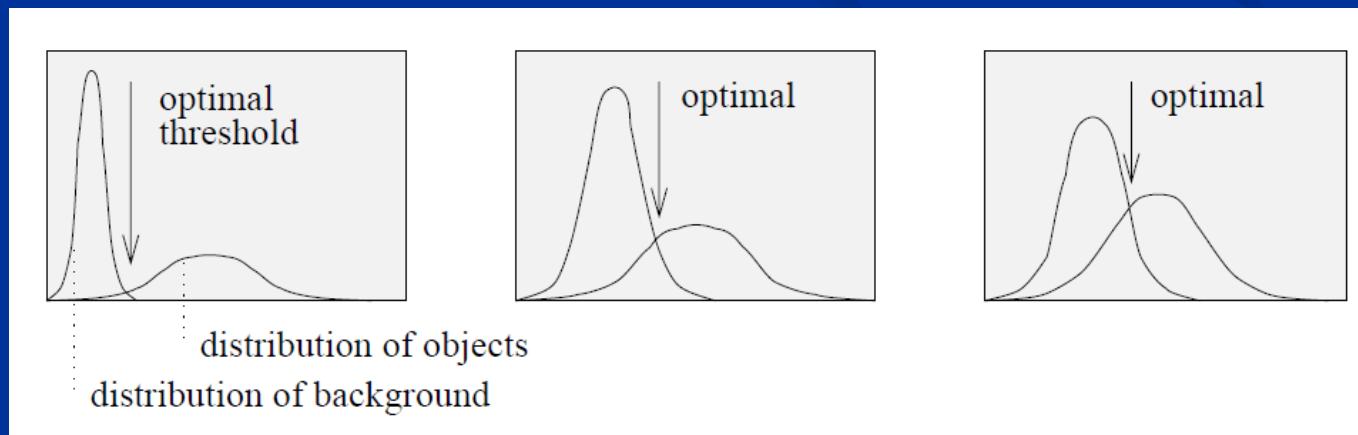
$$g(i, j) = \begin{cases} f(i, j) & \text{for } f(i, j) \geq \text{Threshold}, \\ 0 & \text{for } f(i, j) < \text{Threshold}. \end{cases}$$

# Automatický threshold

$p$ -tile thresholding, ak vieme že objekt pokrýva  $1/p$  obrazu

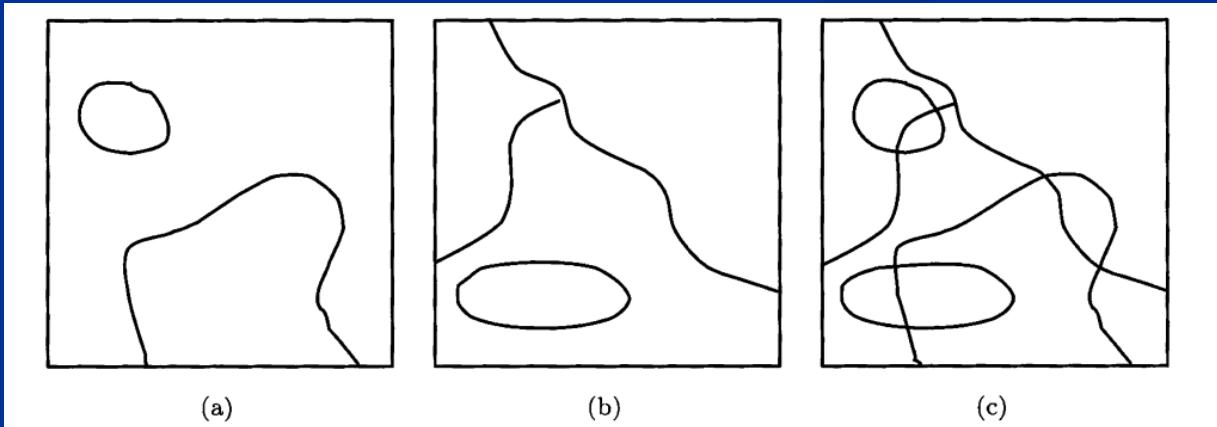
Tlačené znaky na papiery =>  $1/p$  histogramu

**Analýza tvaru histogramu, rôzne objekty na pozadí zodpovedajú bi-modalnemu histogramu. Nájdi stredy medzi módmy**



# Multispektrálne prahovanie

- Multispektrálne kombinuje prahovanie z troch zložiek
  - Farebný obraz
  - Remote sensing
  - Meteorologicke satelitne obrazy



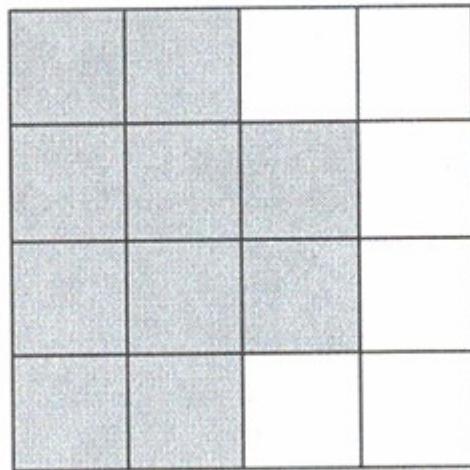
**Figure 6.7:** Recursive multi-spectral thresholding. (a) Band 1 thresholding. (b) Band 2 thresholding. (c) Multi-spectral segmentation.

## ■ Segmentácia leteckej snímky

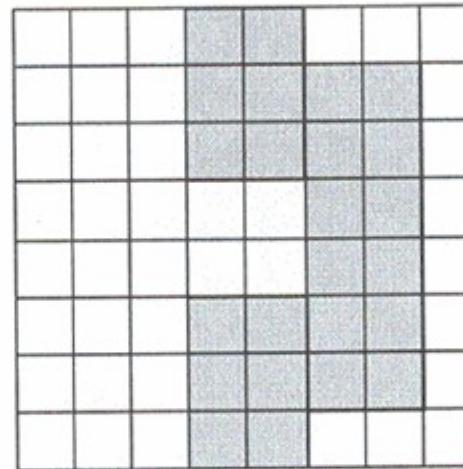


# Hierachické prahovanie

- Hierarchické kombinuje prahovanie z viacerých úrovní



(a)



(b)

Figure 5.8: *Hierarchical thresholding: (a) pyramid level  $n$ , segmentation to objects and background; (b) pyramid level  $n - 1$ , showing where the thresholding must be repeated for better precision.*

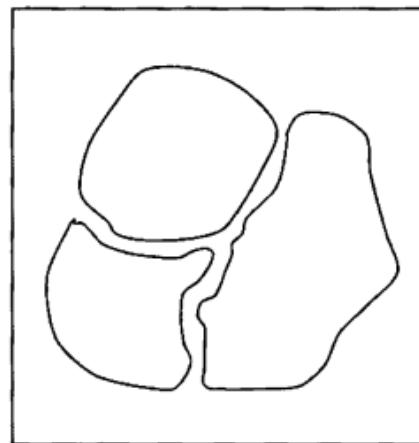
# Segmentácia založená na hranách

- Nájdem hrany (lokálne) potom ich pospájam a vytváram oblasti
  - Sledovanie hranice

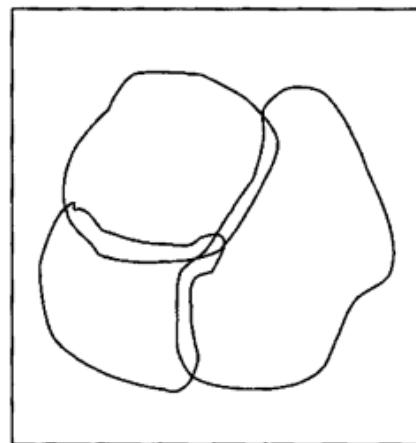
# Sledovanie hranice

- Ak nie je známa hranica, ale v obraze sú známe oblasti, môžeme detegovať hranicu. Poznáme tri typy hranice oblasti:
  - **vnútornú,**
  - **vonkajšiu a**
  - **rozšírenú.**
- Vnútorná hranica je vždy časťou oblasti, ale vonkajšia nikdy nie. Preto dve susedné oblasti nemajú spoločnú hranicu, či použijeme vnútornú hranicu alebo vonkajšiu.

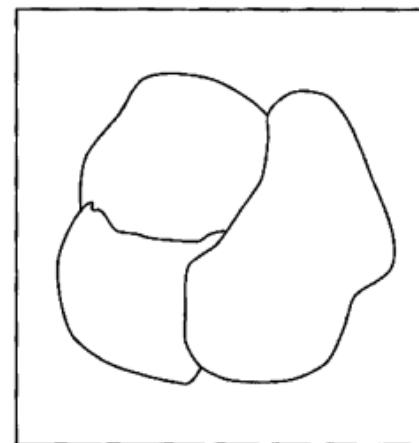
Rozšírená hranica je definovaná ako jednoduchá spoločná hranica medzi dvoma susednými oblastami, ktorá je špecifikovaná súradnicami obrazových bodov. Má lepšie vlastnosti ako vnútorná alebo vonkajšia hranica.



(a)



(b)

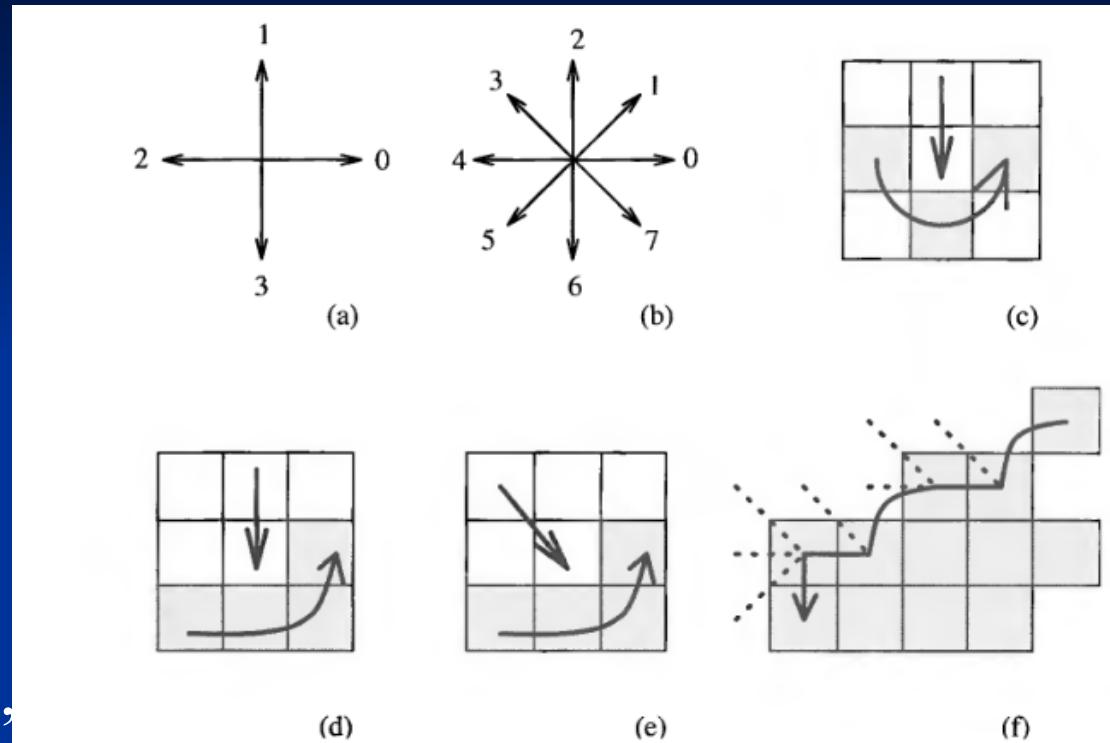


(c)

**Figure 6.16:** Boundary locations for inner, outer, and extended boundary definition. (a) Inner. (b) Outer. (c) Extended.

# Sledovanie vnútornej hranice

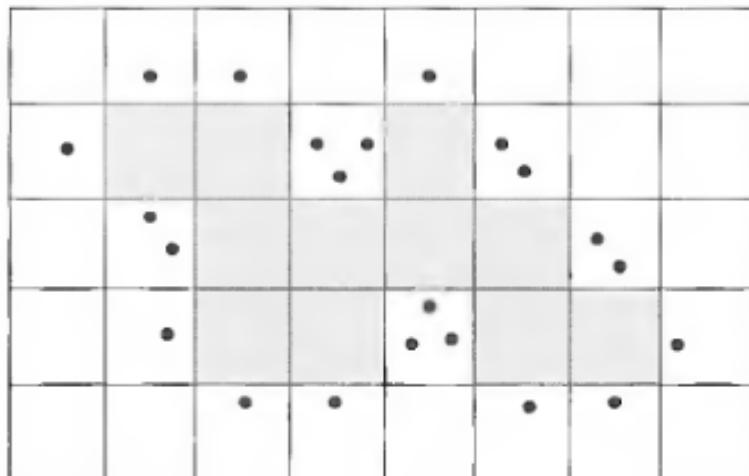
nájdeme najvrchnejší, najľavejší obrazový bod objektu,  
a hľadáme ďalšie body hranice bud' v 4. susednosti alebo  
v 8-susednosti - treba osobitne uvažovať o sledovaní dier.



**Figure 6.14:** Inner boundary tracing. (a) Direction notation, 4-connectivity. (b) 8-connectivity. (c) Pixel neighborhood search sequence in 4-connectivity. (d), (e) Search sequence in 8-connectivity. (f) Boundary tracing in 8-connectivity (dotted lines show pixels tested during the border tracing).

# sledovanie vonkajšej hranice

- niektoré pixle môžu byť súčasťou vonkajšej hranice viackrát.



**Figure 6.15:** Outer boundary tracing; • denotes outer border elements. Note that some pixels may be listed several times.

# Definícia rozšírenej hranice

3	2	1
4	$P$	0
5	6	7

(a)

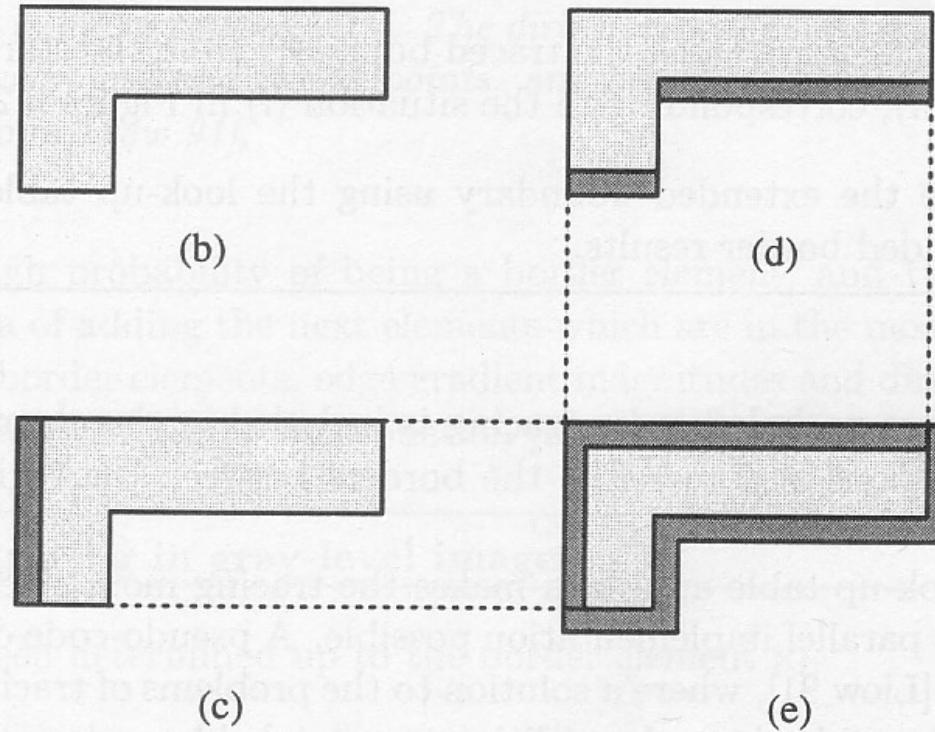


Figure 5.18: *Extended boundary definition:* (a) pixel coding scheme; (b) region  $R$ ; (c)  $LEFT(R)$ ; (d)  $LOWER(R)$ ; (e) extended boundary.

- rozšírená hranica sa vytvára z vonkajšej hranice, jej tvar a veľkosť zodpovedá prirodzenej hranici objektu

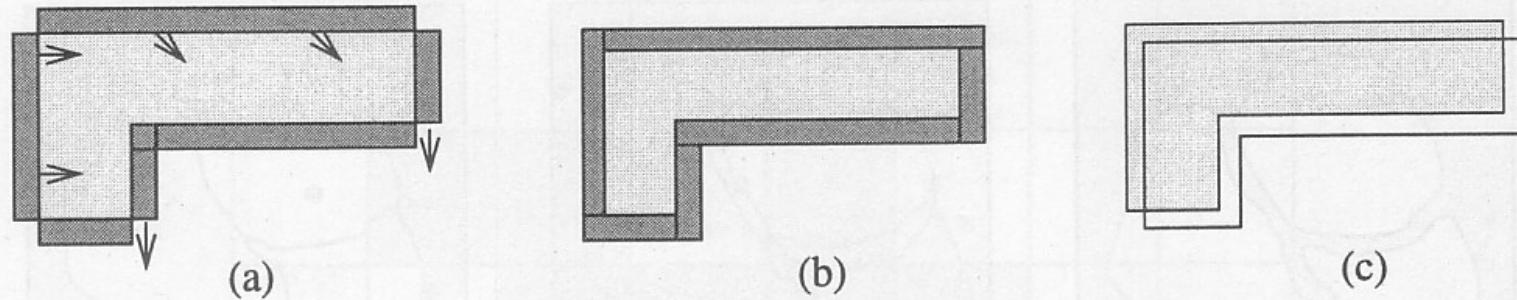
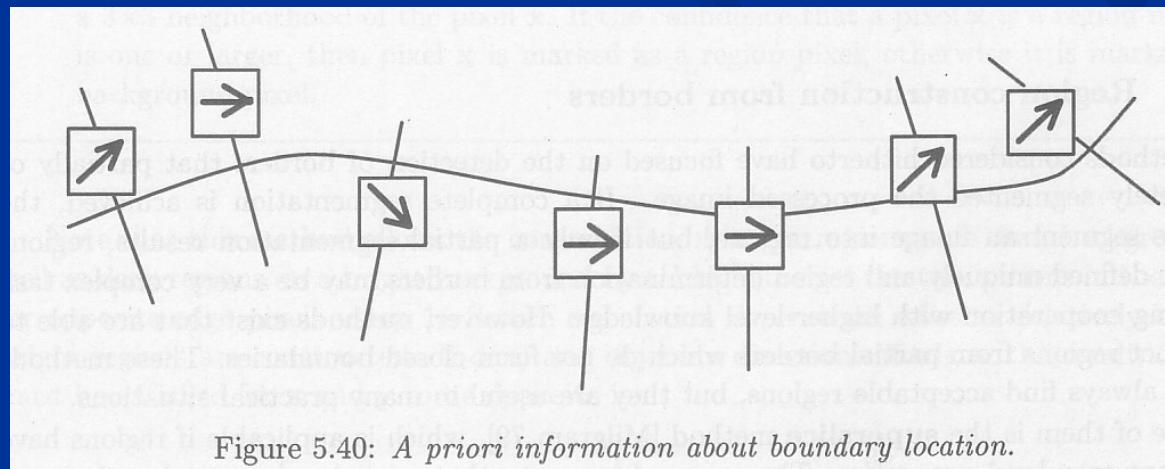


Figure 5.19: *Constructing the extended boundary from outer boundary: (a) outer boundary; (b) extended boundary construction; (c) extended boundary has the same shape and size as the natural object boundary.*

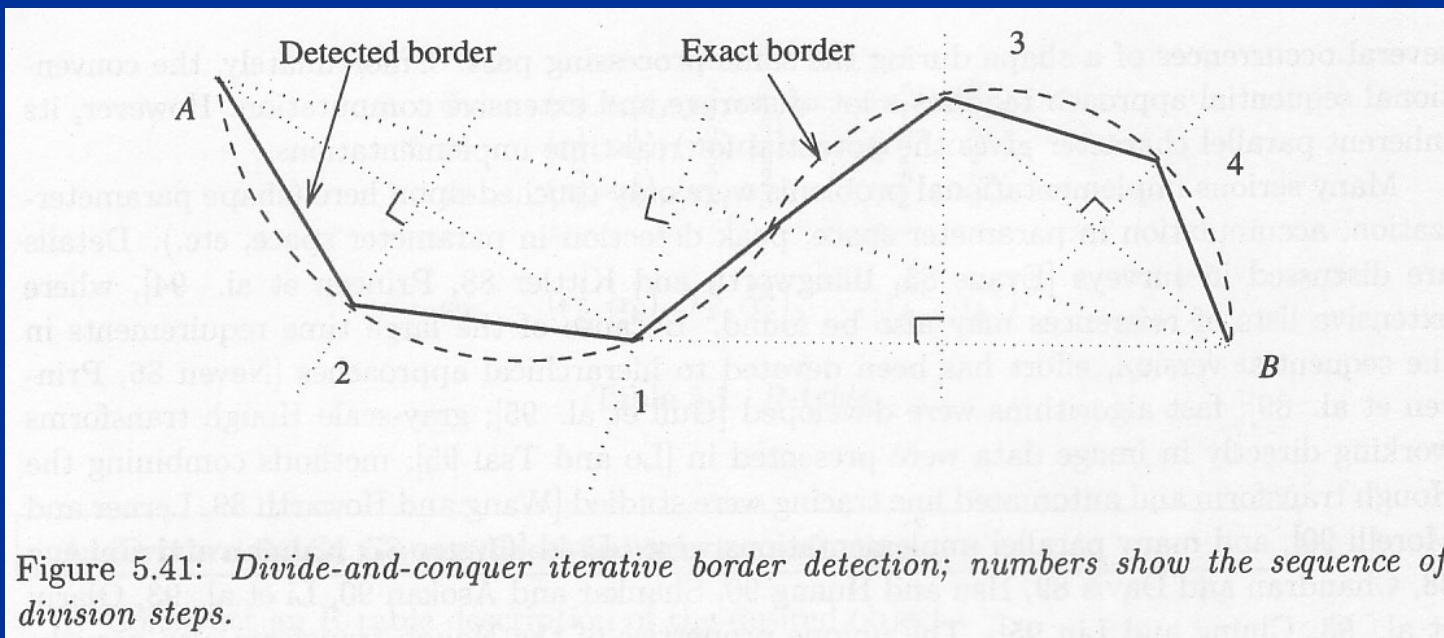
- sledovať hranicu je možné aj v šedo- úrovňových obrazoch, kde zatiaľ neboli identifikované oblasti – potom je hranica reprezentovaná jednoduchou cestou obrazových bodov s vysokým gradientom v obraze.

# Určovanie hranice s využitím informácie o umiestnení hranice

- využíva apriórnu informáciu.
- Tá sa môže získať z nejakej znalosti vyššieho stupňa alebo zo segmentácie na nižšej úrovni rozlíšenia.
- Jedna možnosť je určiť hranicu ako umiestnenie významných lokálnych hrán, ktoré sú blízko k predpokladanej hranici. Nové body hranice sú hľadané v smere kolmom na predpokladanú hranicu.



- Druhá možnosť je založená na apriórnej znalosti koncových bodov, predpokladá sa nízka úroveň šumu a relatívne rovná hranica. Spojnica medzi koncovými bodmi sa iteratívne delí a hľadá sa najsilnejšia hrana umiestnená v smere kolmom na spojnicu medzi dvoma bodmi delenia. Tento proces iteratívne zjemňuje priebeh hranice.



# Určovanie oblasti na základe hranice

- Ak je známa úplná segmentácia - táto úloha je jednoduchá.
- Ak je známa iba čiastočná segmentácia - netriviálne, pretože máme iba časti hranice, ktorá nevytvára uzavretú krivku.

# Určovanie oblasti na základe hranice

- Jedna z metód prahuje dátu z čiastočnej segmentácie s rôznym prahom. Tie oblasti, ktoré sa najlepšie zhodujú s čiastočnými známymi hranicami, sú akceptované ako správne.
- Iná možnosť je využiť pravdepodobnosť toho, že obrazový bod sa nachádza vo vnútri uzavretej oblasti ohraničenej čiastočnou známou hranicou. Body hranice sa popisujú ich polohou a smerom lokálnej hrany. Hľadá sa protiľahlý pixel hrany.

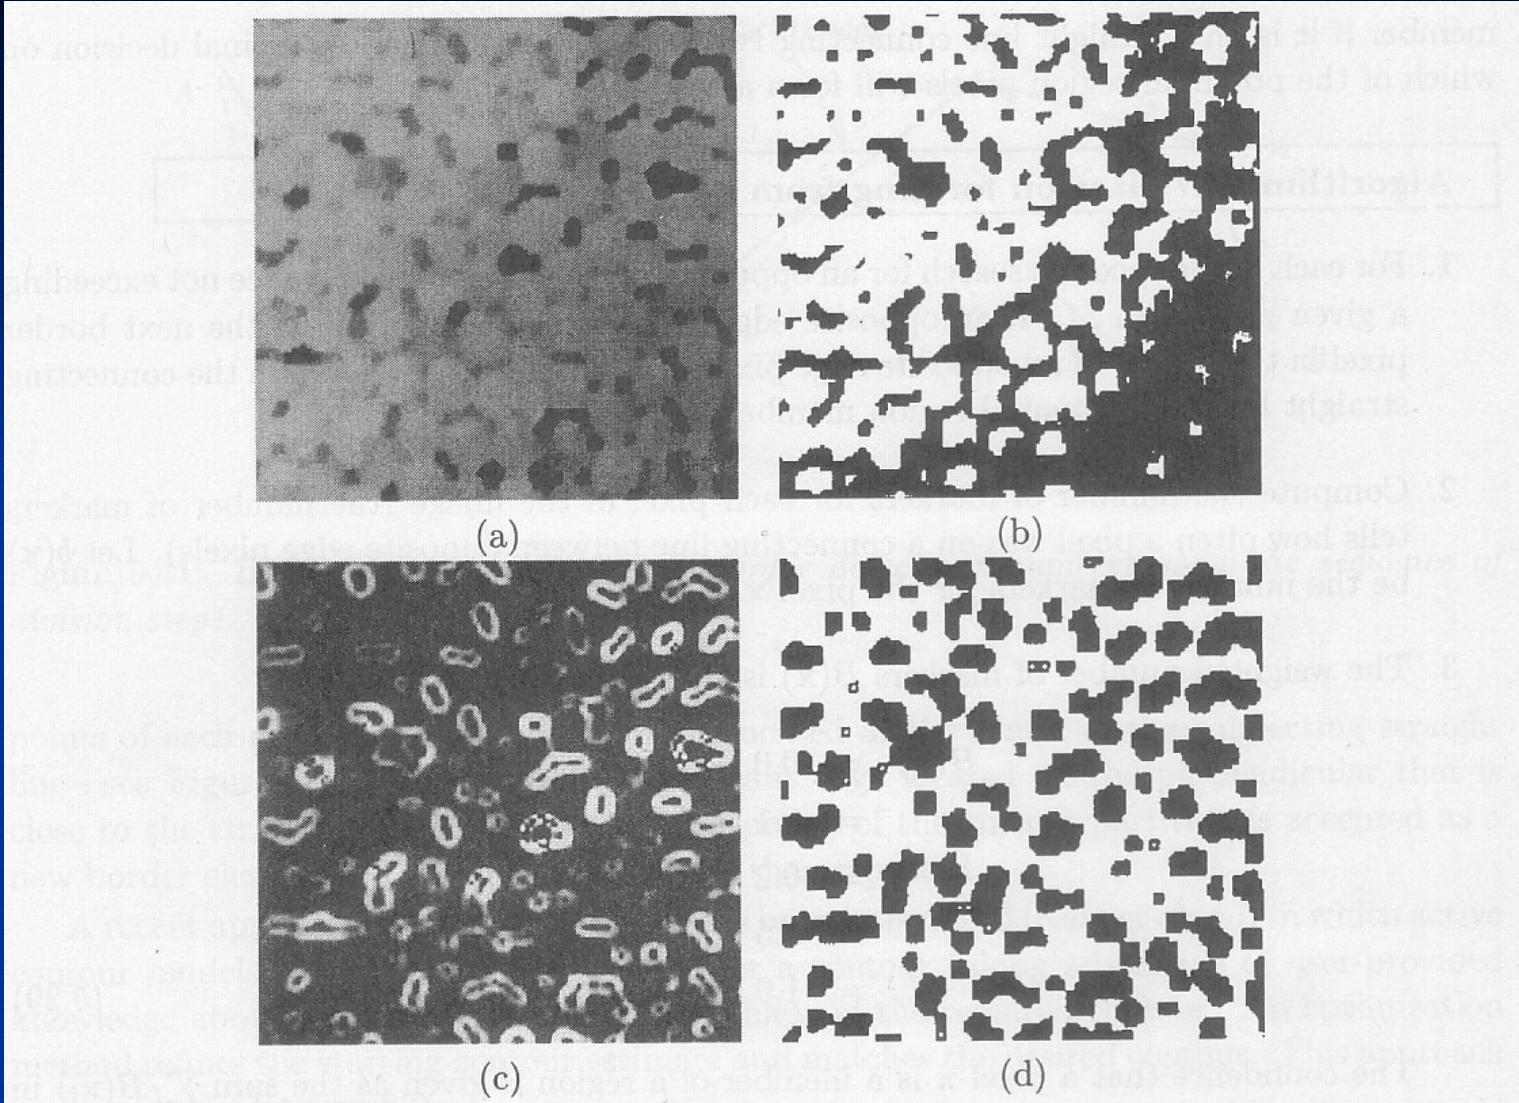


Figure 5.42: *Region forming from partial borders*: (a) *original image*; (b) *thresholding*; (c) *edge image*; (d) *regions formed from partial borders*.

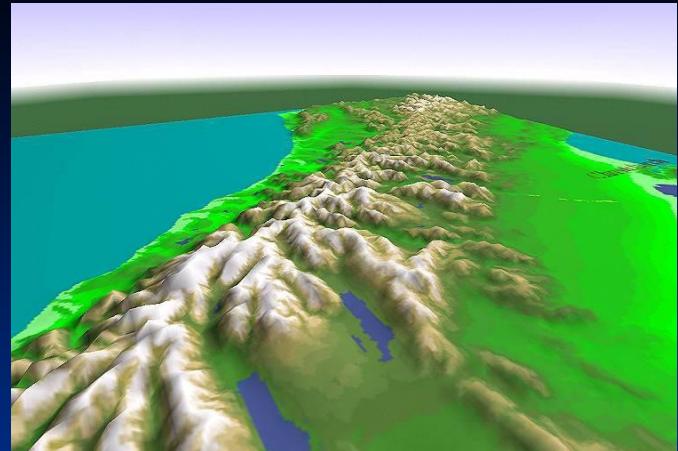
# Simultánne hľadanie hranice

- Umožňuje optimálnu identifikáciu hranice nájdením optimálnej cesty v trojrozmernom grafe.
- Je založené na pozorovaní, že informácia, obsiahnutá v polohe jednej hranice môže byť užitočná pre identifikáciu polohy druhej hranice.
- Ak sa definuje ohodnocovacia funkcia, ktorá kombinuje cenu hrany z ľavej a pravej časti hranice, potom je možné použiť na optimálnu detekciu hranice buď heuristické hľadanie v grafe alebo metódy dynamického programovania.

# Segmentácia na základe regiónov

- Zgrupovanie - clustering
- Narastanie regiónu – region growing
- Split and merge

# Watershed - segmentácia s využitím povodí



- Pri tejto metóde reprezentujú oblasti segmentovaného obrazu zberné nádrže, a reprezentujú lokálne minimum šedej úrovne.

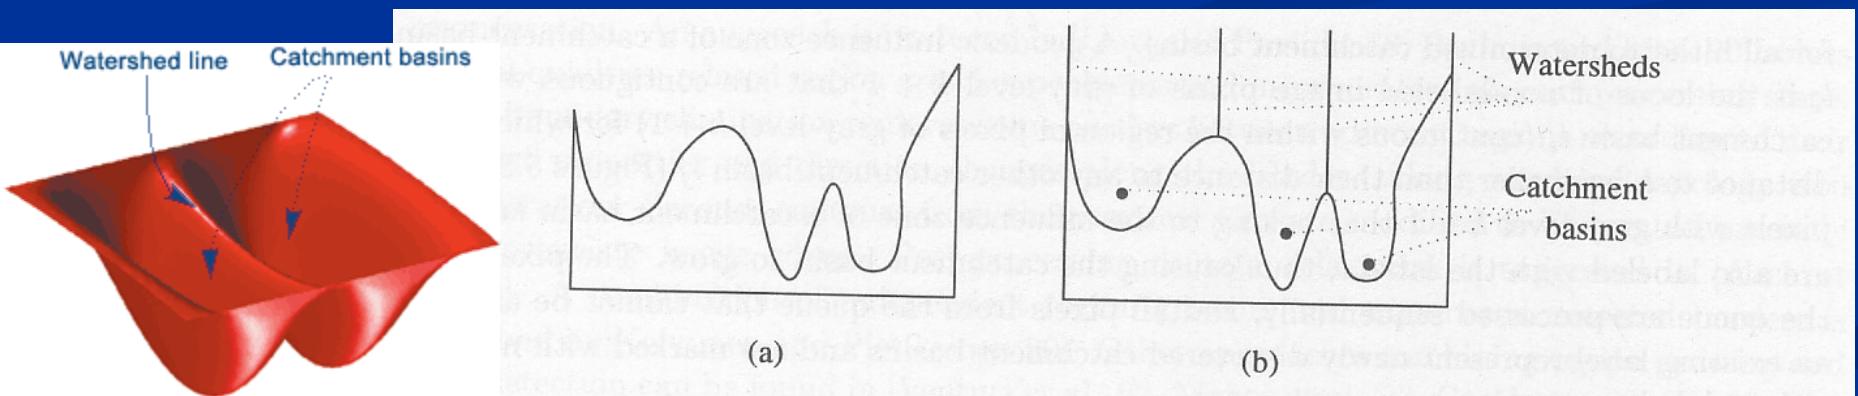


Figure 5.49: One-dimensional example of watershed segmentation: (a) gray-level profile of image data; (b) watershed segmentation—local minima of gray-level (altitude) yield catchment basins, local maxima define the watershed lines.

# Dva prístupy pre watershed

- Prvý prístup cez watershed segmentáciu spočíva v nájdení cesty vedúcej od daného pixla smerom dolu k lokálnemu minimu v zbernej nádrži. Tu sa pixle usporiadajú podľa toho, v ktorom minime sa skončí ich cesta.
- Pri druhom prístupe každé minimum šedej úrovne reprezentuje jednu zbernú nádrž a stratégia spočíva v plnení týchto nádrží smerom nahor.

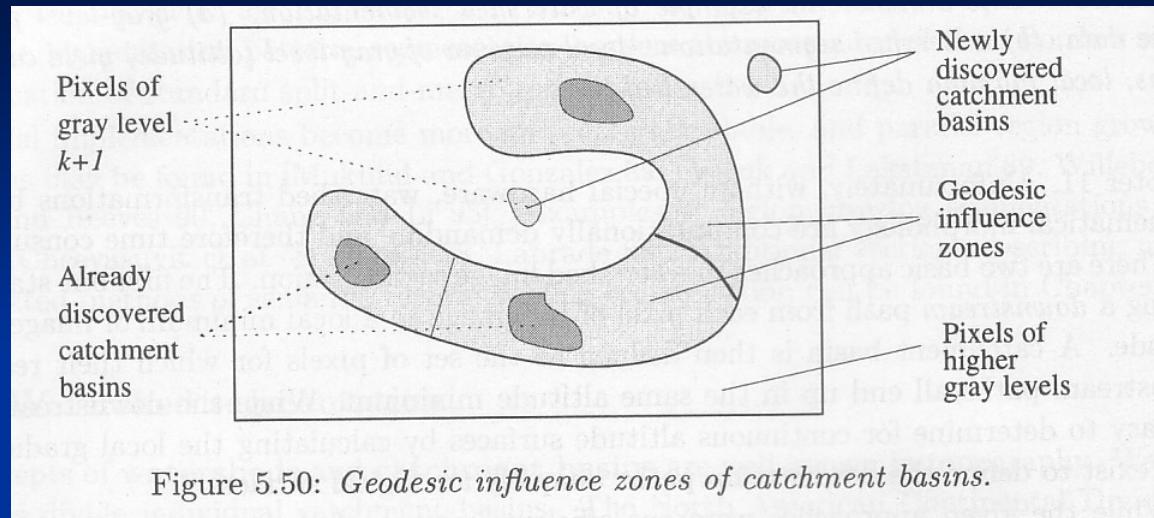
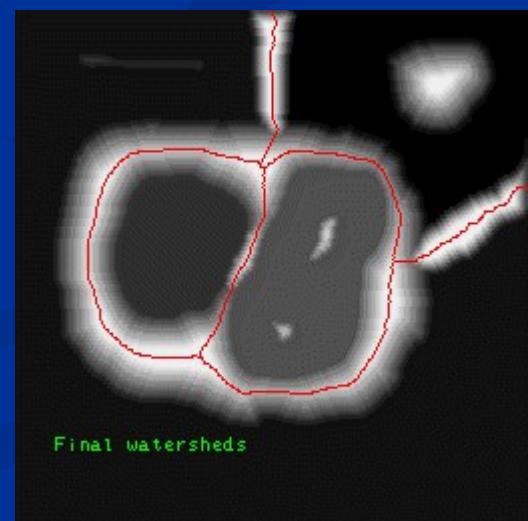
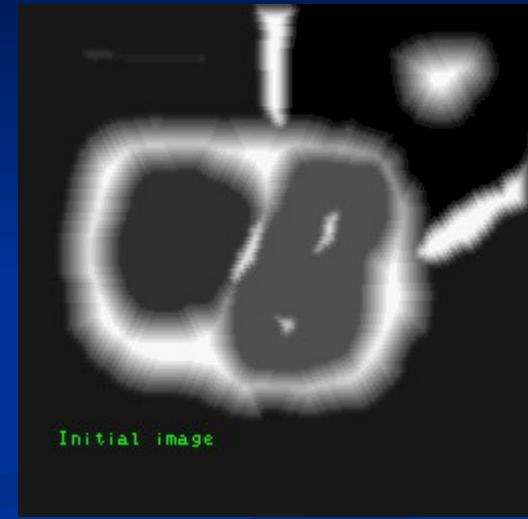
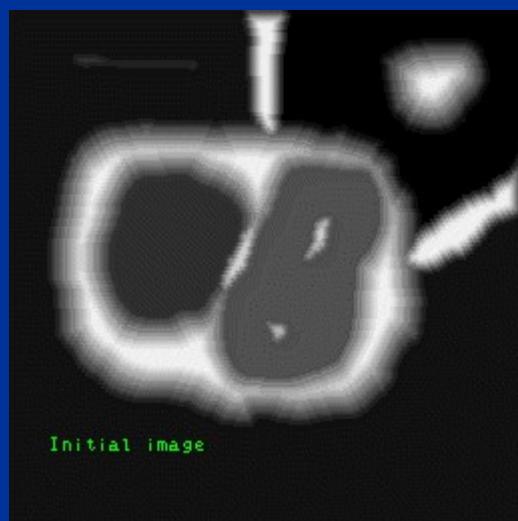


Figure 5.50: *Geodesic influence zones of catchment basins.*



# Výpočtová zložitosť

- Sortovanie  $O(n \log n)$
- Watershed  $O(n)$ 
  - Obraz obvykle 256 úrovní šedej => bin sort  $O(n)$

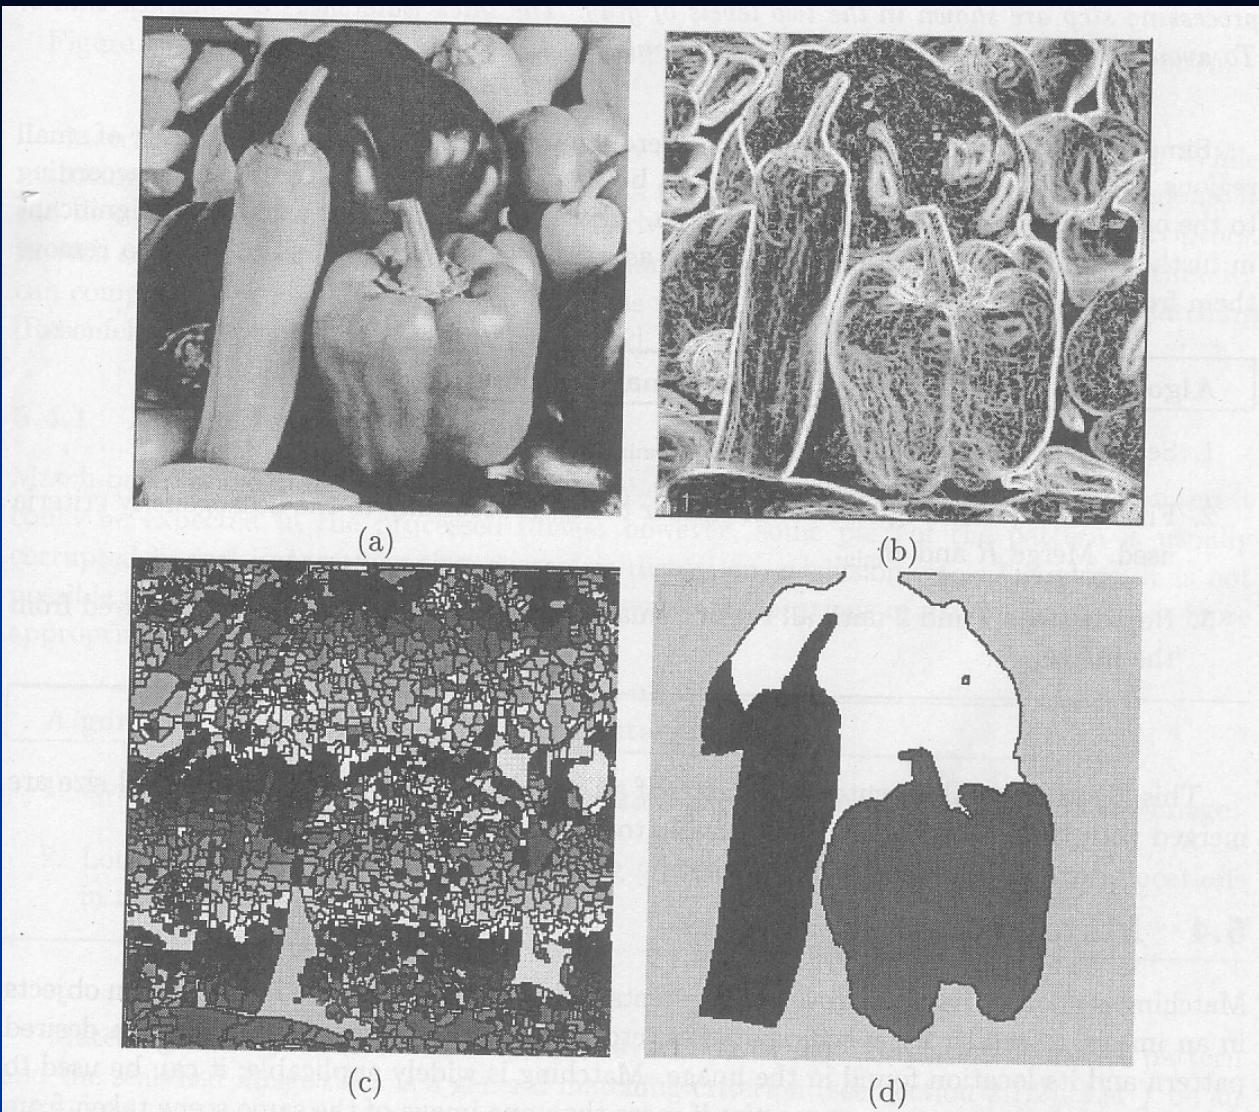
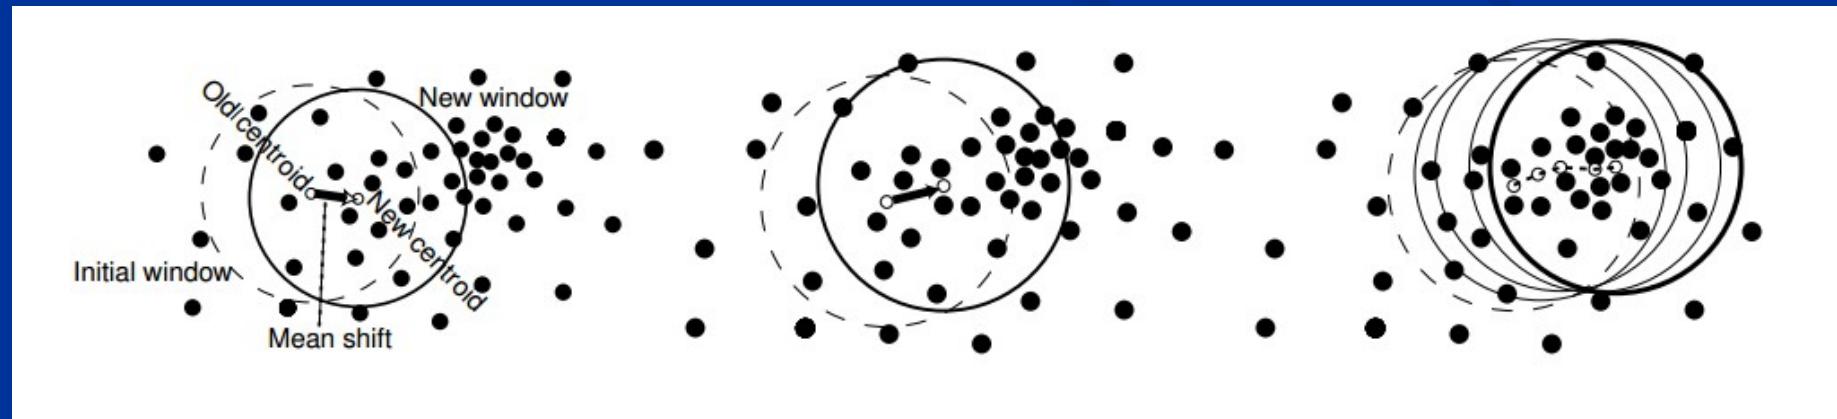


Figure 5.51: *Watershed segmentation: (a) original; (b) gradient image,  $3 \times 3$  Sobel edge detection, histogram equalized; (c) raw watershed segmentation; (d) watershed segmentation using region markers to control oversegmentation. Courtesy W. Higgins, Penn State University.*

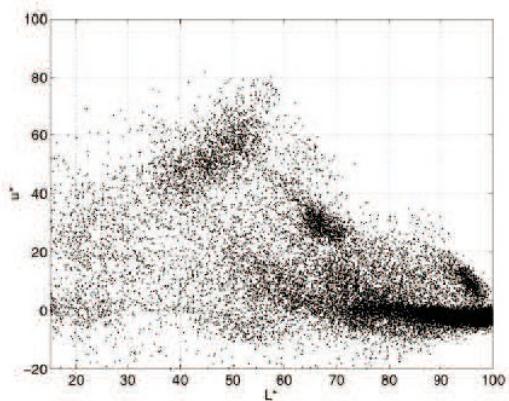
# Mean-shift

- zhlukuje body obrazu (pixely) na základe podobnosti ich vzhľadu a blízkosti ich pozície pomocou konvergencie do lokálnych maxím spojeného súradnicového a intenzitného priestoru

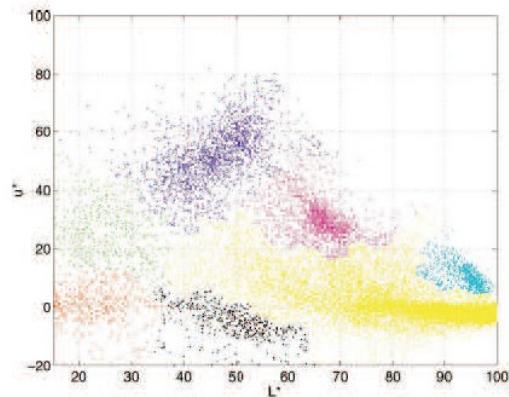


# Mean-shift

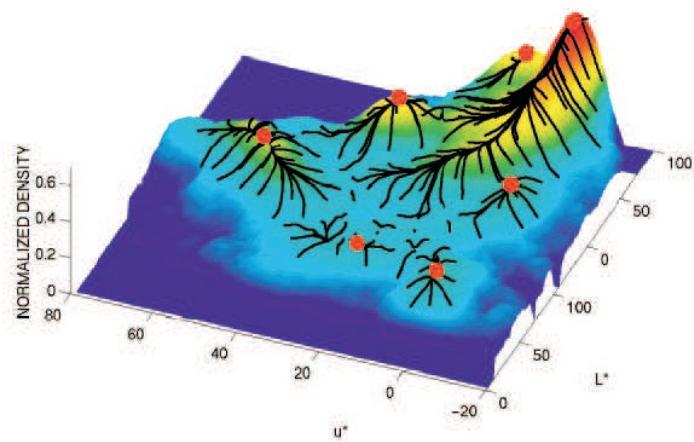
- v každej iterácii pre určitú pozíciu počíta gradient hustoty bodov v blízkom okolí a pohybuje sa v smere gradientu, až kým nedosiahne lokálne maximum
- tento proces je iniciovaný v každom bode výsledok
- súradnice lokálneho maxima pre každý bod
- zhľukovanie obrazových bodov (pixlov), ktoré dokonvergovali do rovnakého maxima s určitou toleranciou



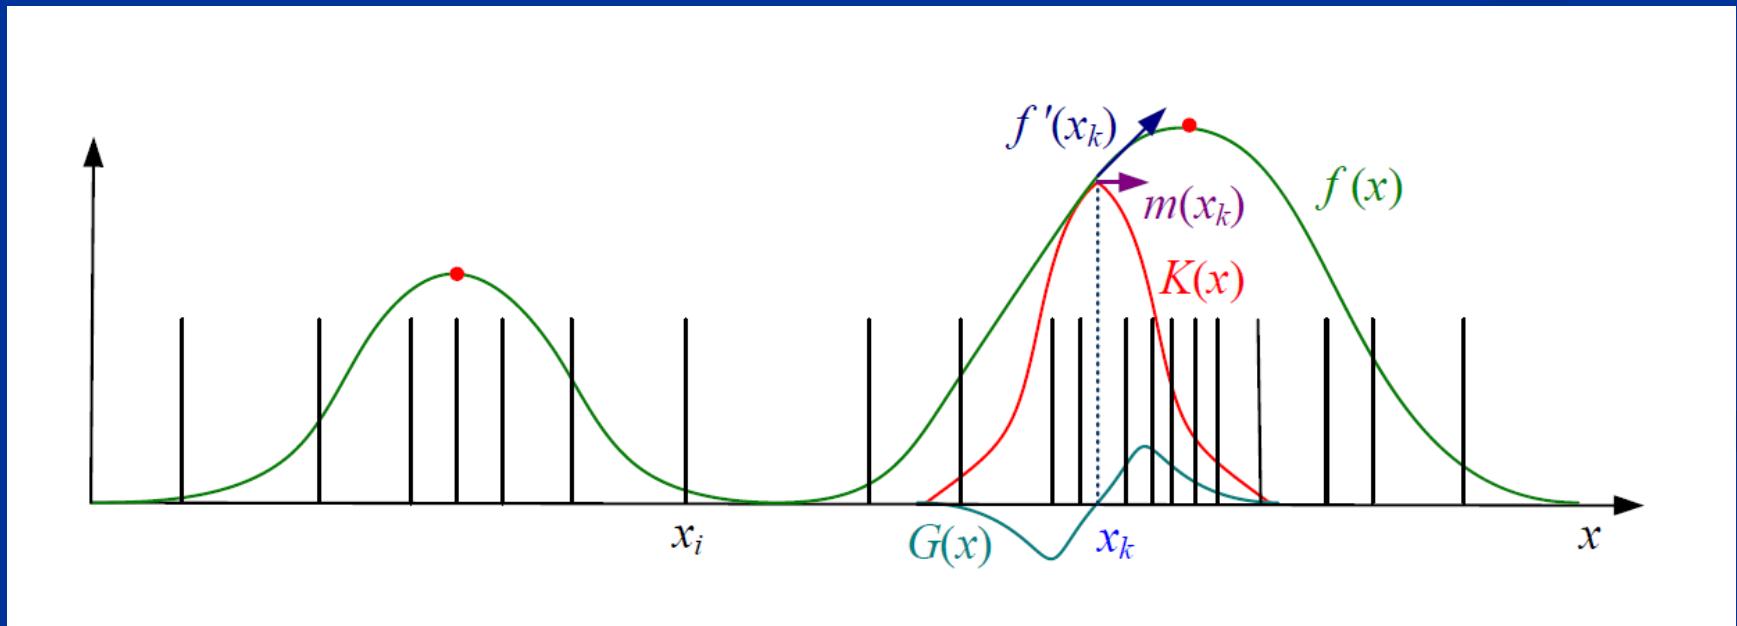
(a)



(b)

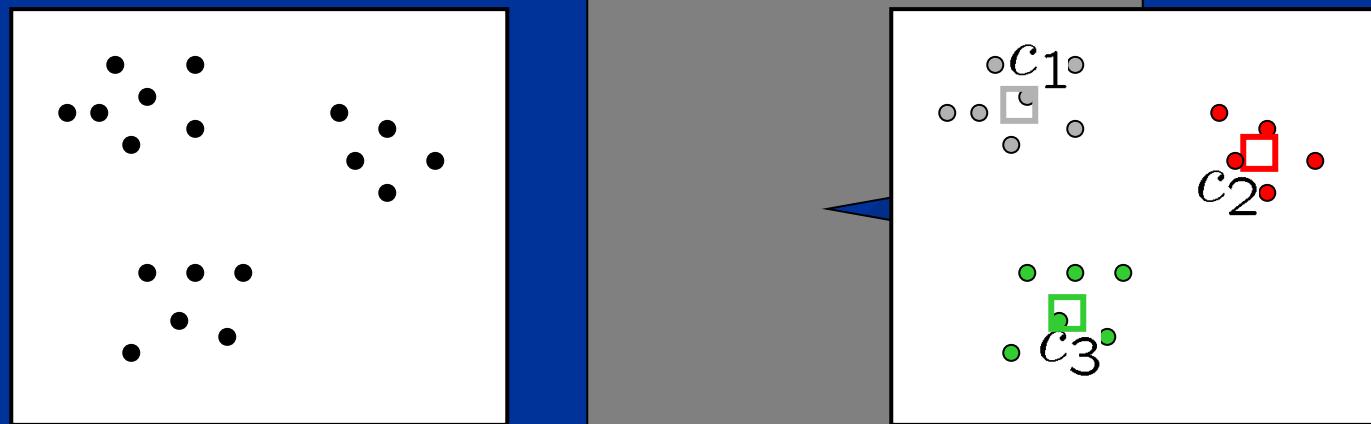


$$f(\mathbf{x}) = \sum_i K(\mathbf{x} - \mathbf{x}_i) = \sum_i k \left( \frac{\|\mathbf{x} - \mathbf{x}_i\|^2}{h^2} \right)$$



# Clustering-based segmentation

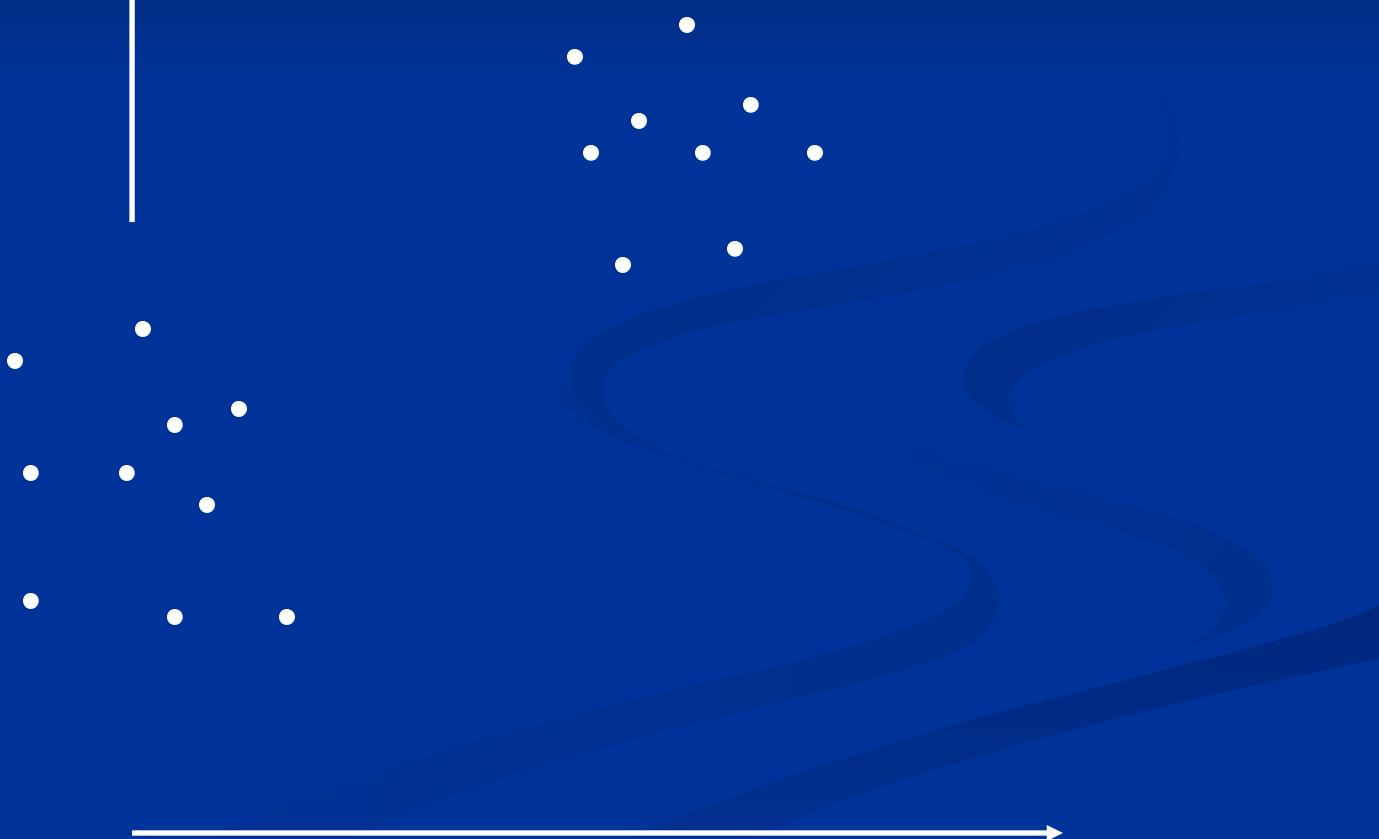
- Môžeme použiť K-means algoritmus



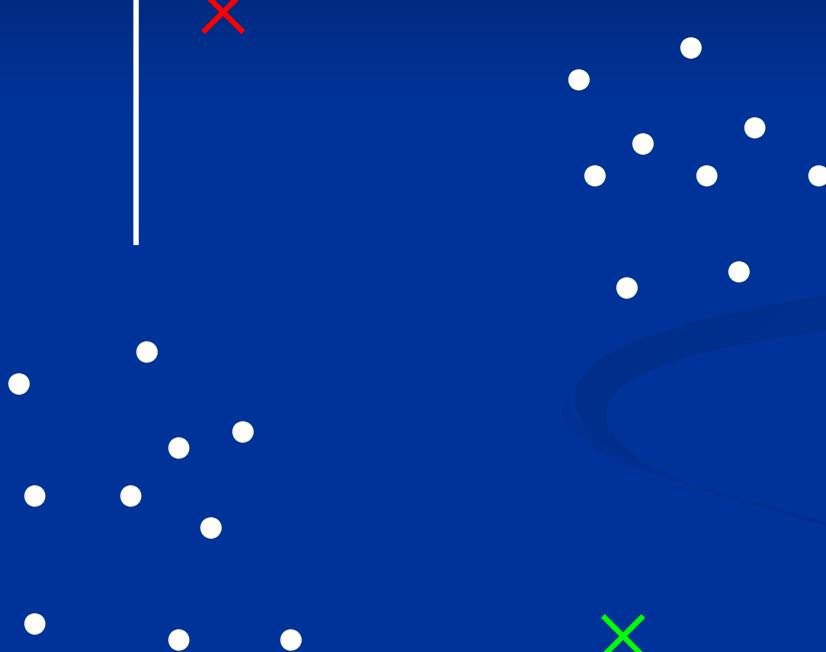
# K-Means Clustering

- Vygeneruj začiatočné rozdelenie
- Nájdi centroid každého zhluku
- Pre každú farbu:
  - Vyrátaj vzdialenosť od každého centroidu
  - Prirad' k najbližšiemu zhluku
- Vyrátaj nové centroidy
- Opakuj, kým nie sú zhluky stabilné ( $MSE < \text{prah}$ )

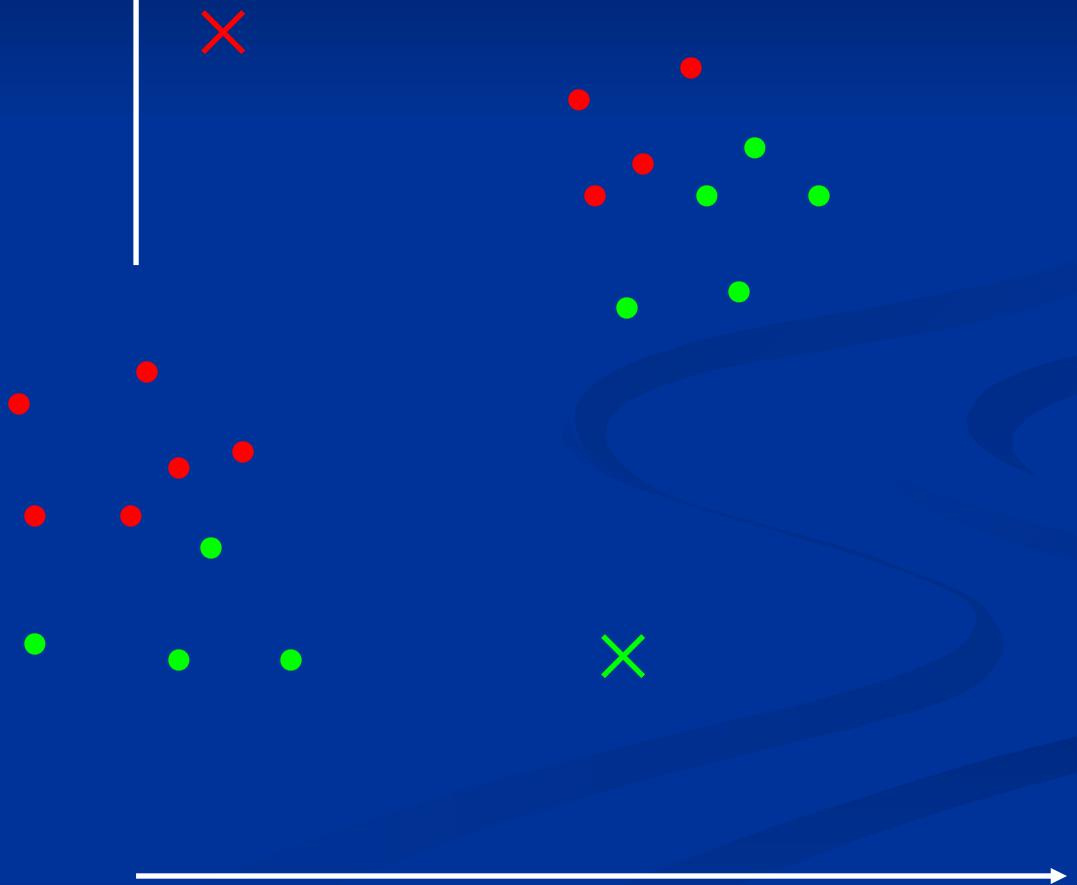
# K-Means Clustering



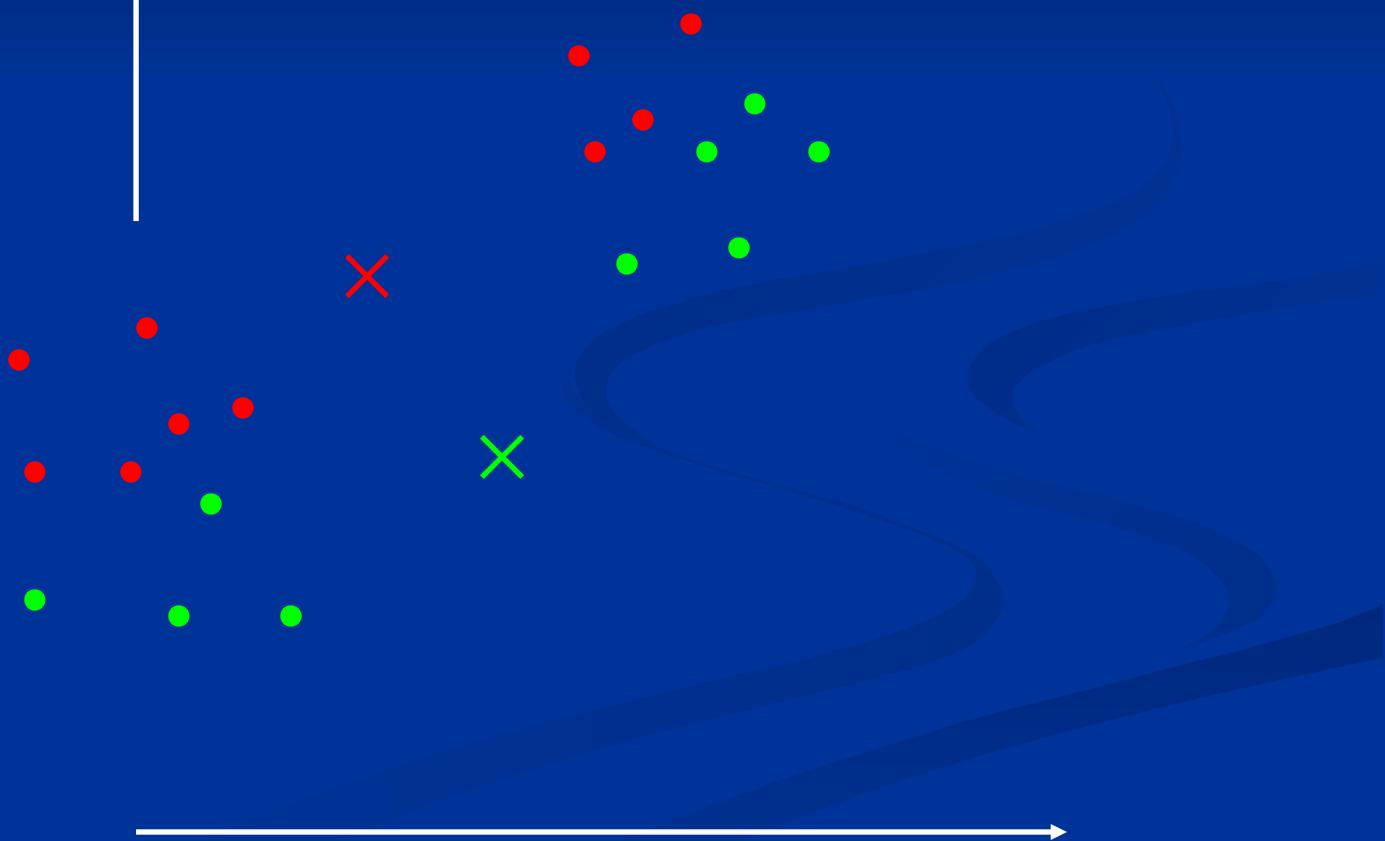
# K-Means Clustering



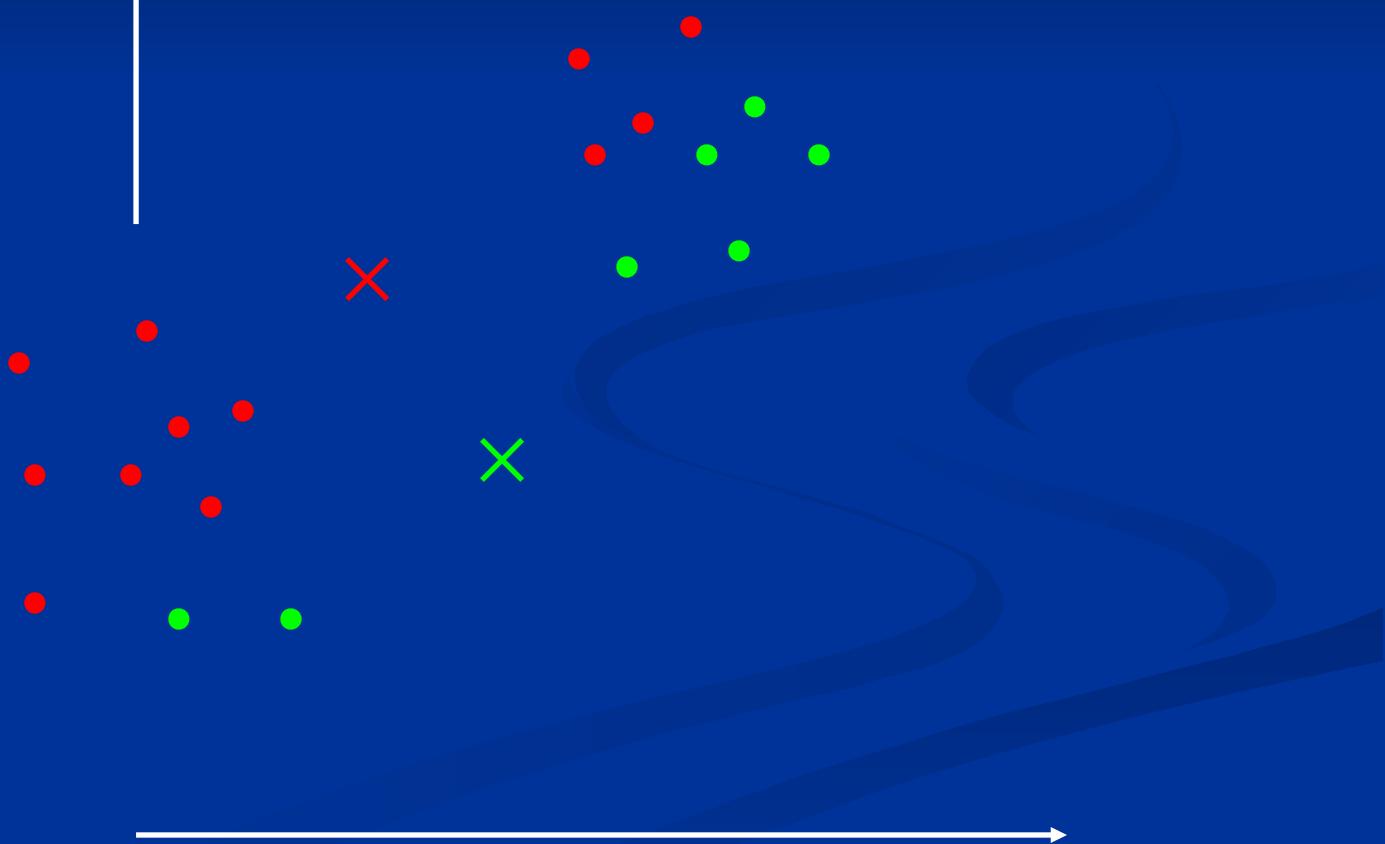
# K-Means Clustering



# K-Means Clustering



# K-Means Clustering



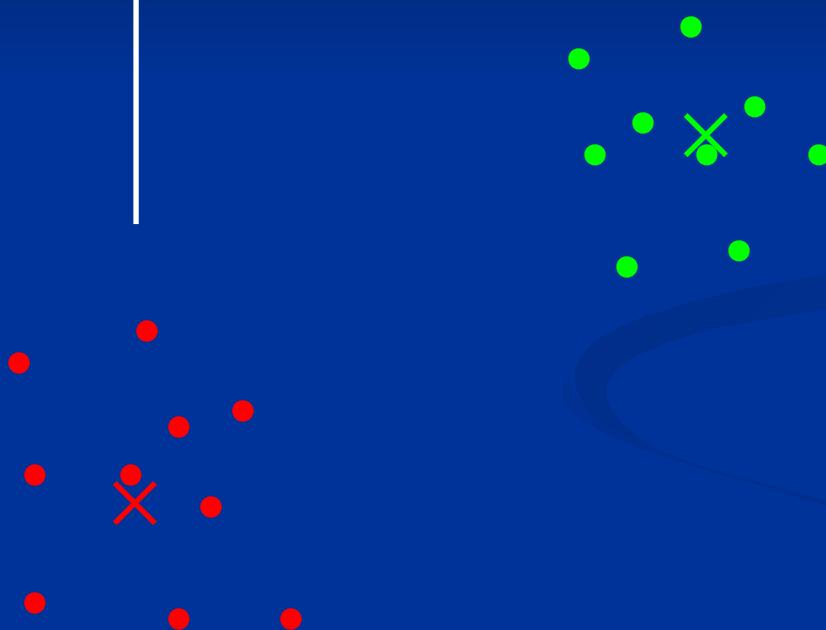
# K-Means Clustering



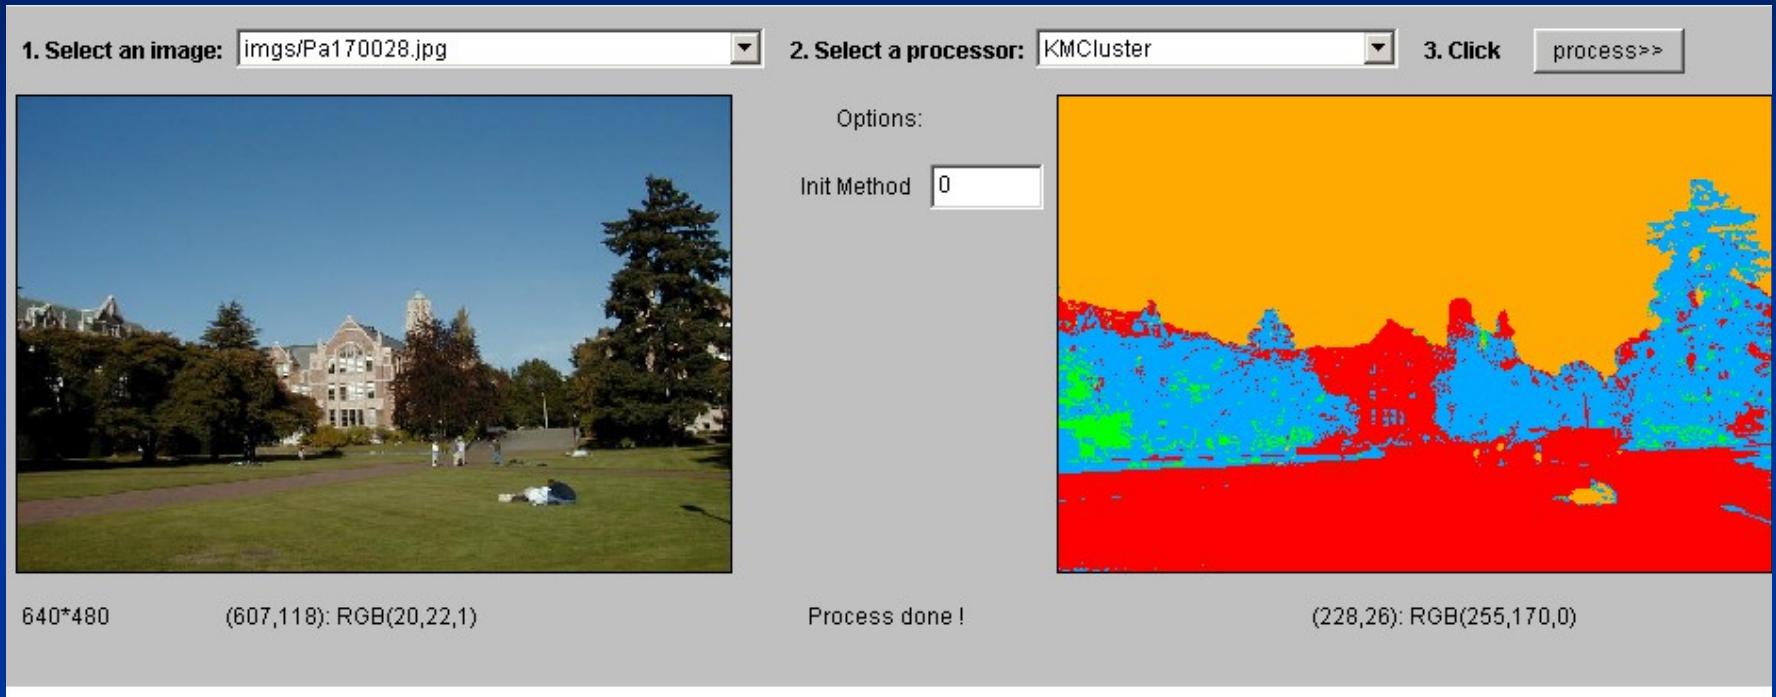
# K-Means Clustering



# K-Means Clustering

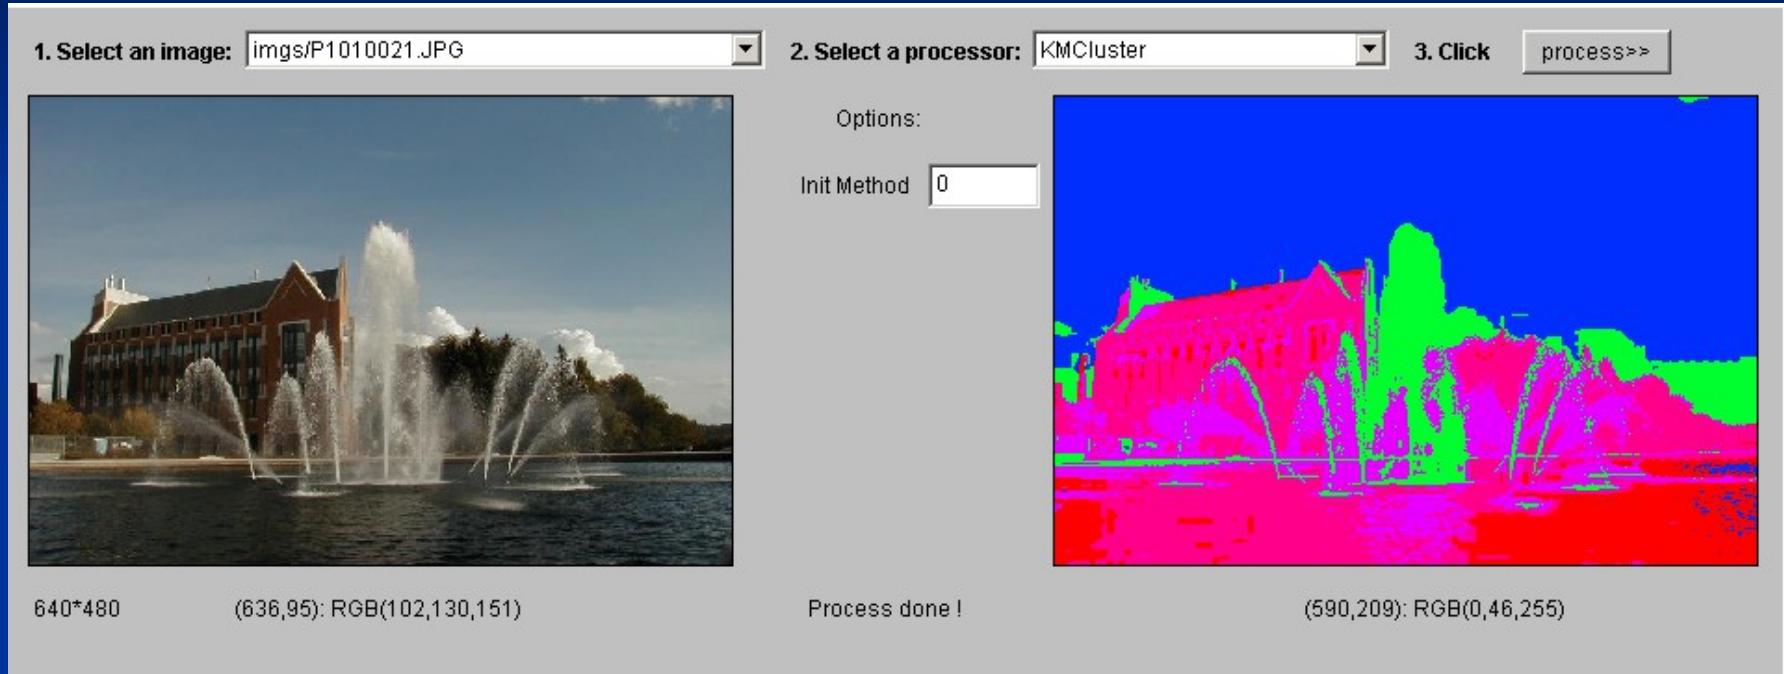


# Clustering-based segmentation



K-means clustering of color.

# Clustering-based segmentation



K-means clustering of color.

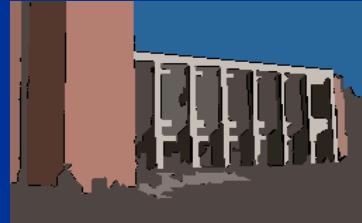
# Clustering-based segmentation

## ■ Clustering na základe farby a textúry

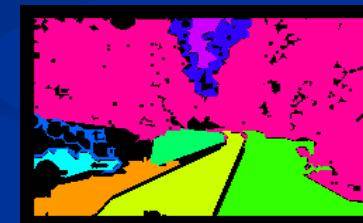
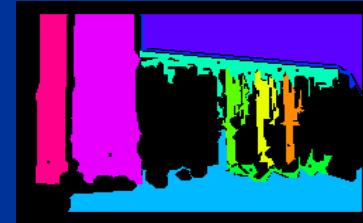
Original Images



Color Regions



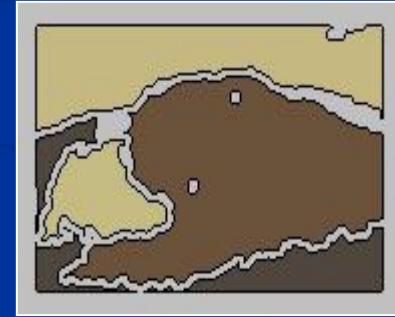
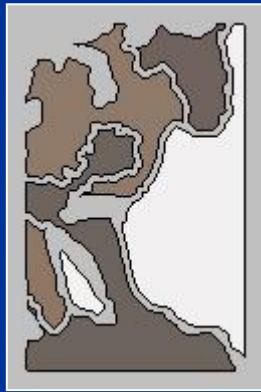
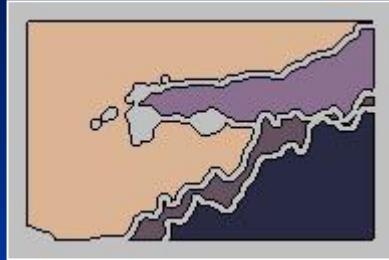
Texture Regions



# Clustering-based segmentation

- K-means rôzne variácie:
  - Rôzne spôsoby inicializácie.
  - Rôzne zastavovacie pravidla.
  - Dynamické metódy určovania správneho počtu grúp K pre daný obraz
- Problém: segmentácie na základe histogramov a klasteringu môžu produkovať nejednoznačné regióny.

# Clustering-based segmentation



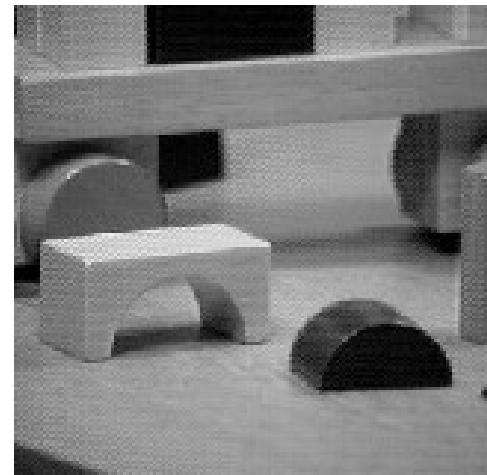
Examples from the UC Berkeley's Blobworld system.

# Region growing – narastanie regiónu

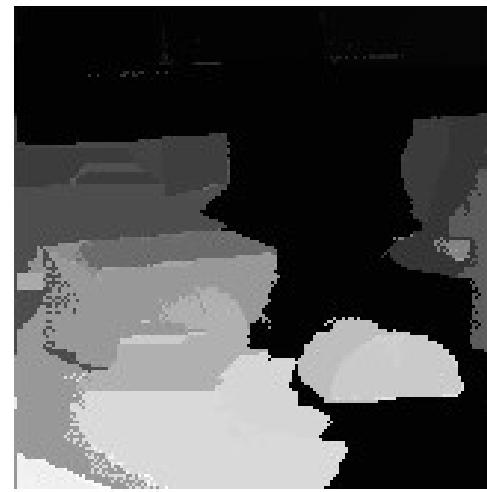
- Narastanie regiónu začína s jedným pixelom potencionálneho regiónu (seed) a snaží sa narastať pridávaním pixlov na základe podobnosti.
- Prvý vybraný pixel môže byť buď prvý neoznačený pixel alebo z množiny „seeds“ určenej pre daný obraz
- Zvyčajne sa používajú štatistické texty na určenie ktorý pixel môže byť pridaný k skúmanému regiónu
  - Región je populácia s podobnými vlastnosťami

# Region growing

image



segmentation



# Techniky dodatočného spracovania narastania oblastí

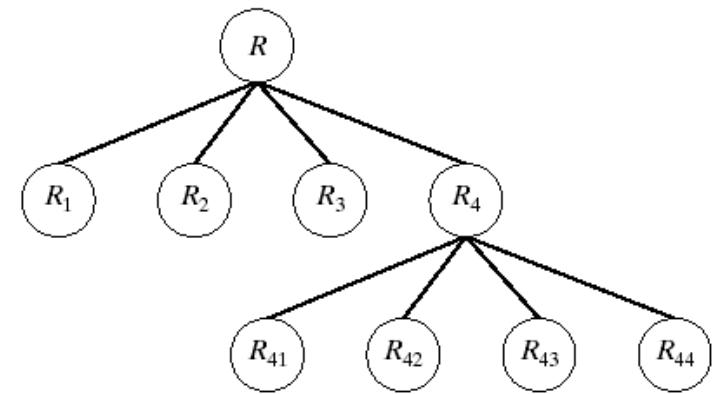
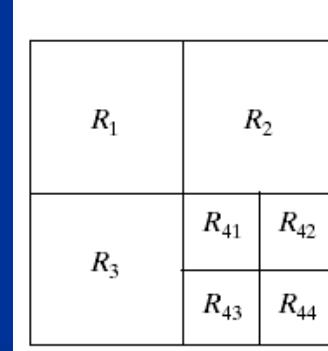
- obrazy segmentované narastaním oblastí často obsahujú príliš veľa oblastí (slabé narastanie) alebo príliš málo oblastí (silné narastanie) ako výsledok neoptimálneho nastavenia parametrov.
- Na zlepšenie segmentačných výsledkov bolo vytvorených viacero techník dodatočného spracovania.

- Jednoduchšie techniky dodatočného spracovania znížia počet malých oblastí v segmentovanom obraze.
  - V jednom kroku sa odstraňujú hranice medzi susednými oblasťami vzhľadom na ich kontrast a zmeny smeru pozdĺž hranice.
  - V druhom kroku sa výsledky prvého kroku modifikujú tak, aby pasovali presne so známymi obrazovými hranami.

# Split-and-merge

1. Start with the whole image.
2. If the variance is too high, break into quadrants.
3. Merge any adjacent regions that are similar enough.
4. Repeat steps 2 and 3, iteratively until no more splitting or merging occur.

→ Idea: good  
Results: blocky



# Split-and-merge

Split and merge example



VIVIB004-20C7213-C78/D01  
Image Processing.

82

Split and merge example

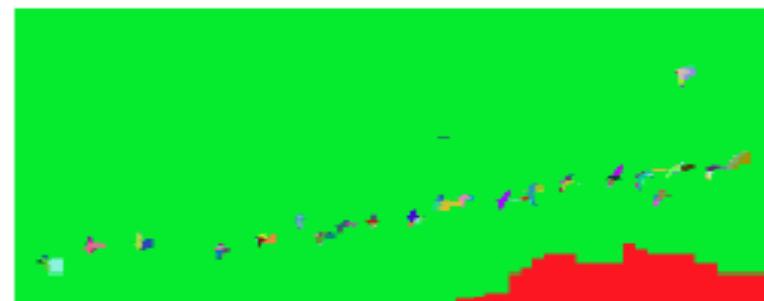


4087 regions

VIVIB004-20C7213-C78/D01  
Image Processing.

83

Split and merge example

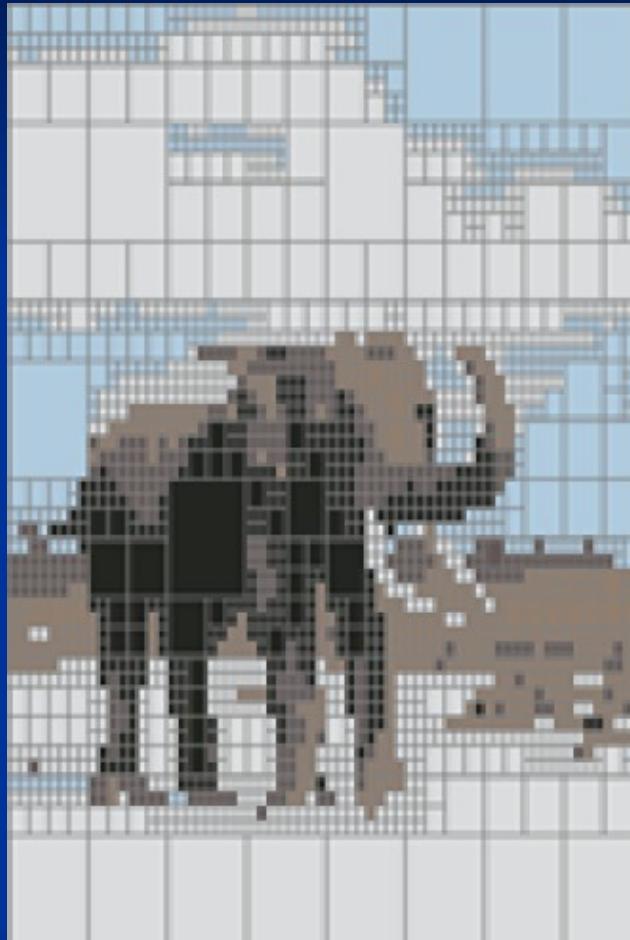


135 regions

VIVIB004-20C7213-C78/D01  
Image Processing.

84

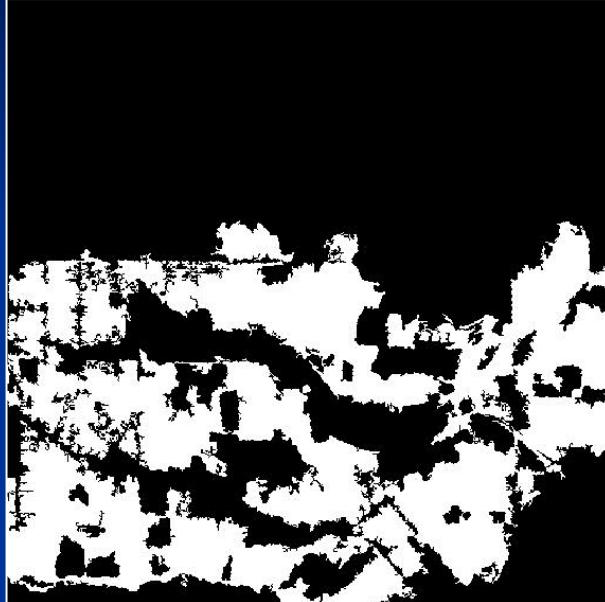
# Split-and-merge



# Split-and-merge



A satellite image.



A large connected region formed by merging pixels labeled as residential after classification.

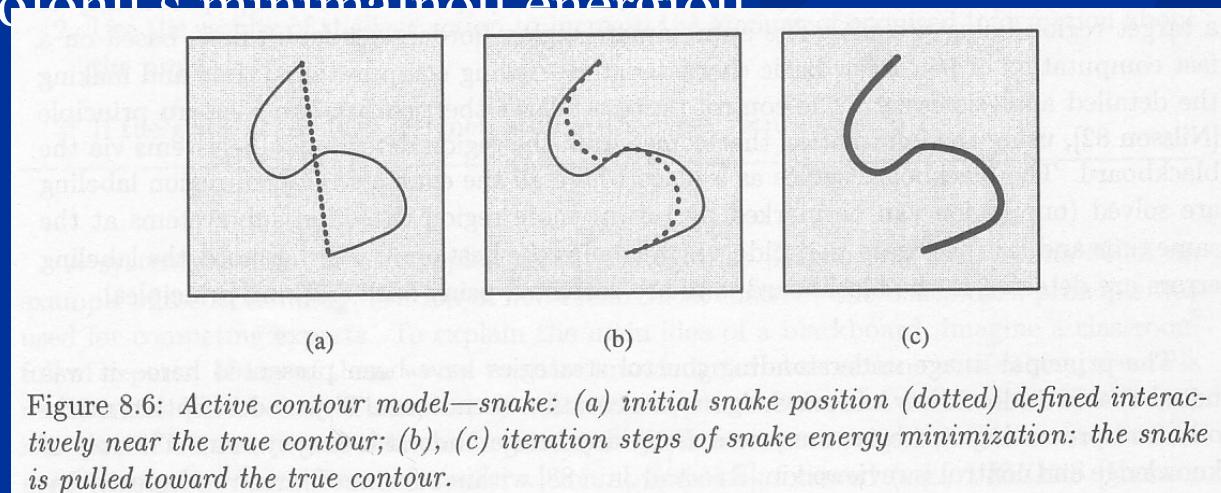


More compact sub-regions after the split-and-merge procedure.

# Modeley aktívnej hranice – hady (snakes)

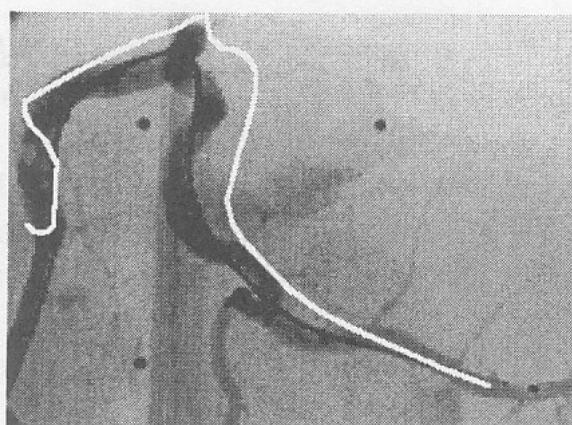
- Had je spline, ktorý minimalizuje energiu – pričom energia závisí na jeho tvare a umiestnení v obraze.
- Lokálne minimá tejto energie zodpovedajú hľadaným vlastnostiam obrazu.
- Funkcia energie, ktorá sa minimalizuje je vážená kombinácia interných a externých síl.

- Modely aktívnej hranice sa používajú pri segmentácii, porozumení obrazu a pri analýze dynamických obrazových dát.
- Hady sami neriešia problém nájdenia hranice, ale robia to v interakcii s užívateľom alebo nejakým vyšším procesom porozumenia.
- Táto interakcia musí špecifikovať počiatočný bod a približný tvar hranice.
- Apriórna informácia posúva hada k vhodnému riešeniu.
- Na rozdiel od ostatných modelov obrazu, had je aktívny, vždy si hľadá polohu s **minimálnou energiou**.

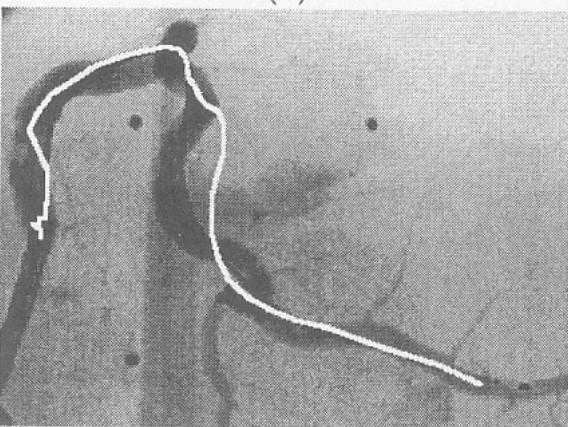




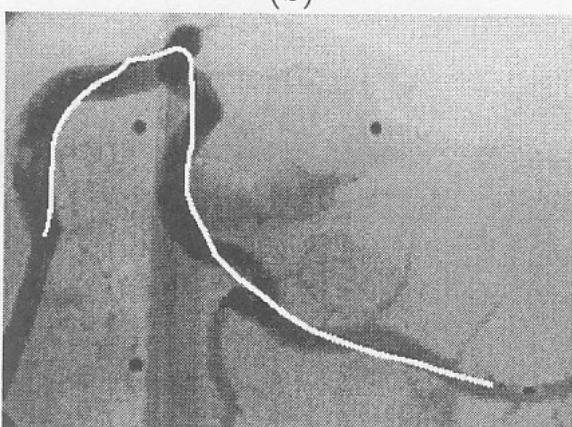
(a)



(b)



(c)



(d)

Figure 8.7: *Snake-based detection of the untraversable ultrasound catheter (dark line positioned inside the coronary artery lumen) in an angiographic X-ray image of a pig heart: (a) original angiogram; (b) initial position of the snake; (c) snake deformation after 4 iterations; (d) final position of the snake after 10 iterations.*

- Funkcia energie, ktorá sa minimalizuje, je vážená kombinácia vnútorných a vonkajších síl.
- Vnútorné sily vyplývajú z tvaru hada, kým externé sily z obrazu a/alebo z vyšších úrovní porozumenia.
- Had je definovaný parametricky ako

$$\mathbf{v}(s) = [x(s), y(s)],$$

kde  $x(s)$  a  $y(s)$  sú súradnice pozdĺž hranice a

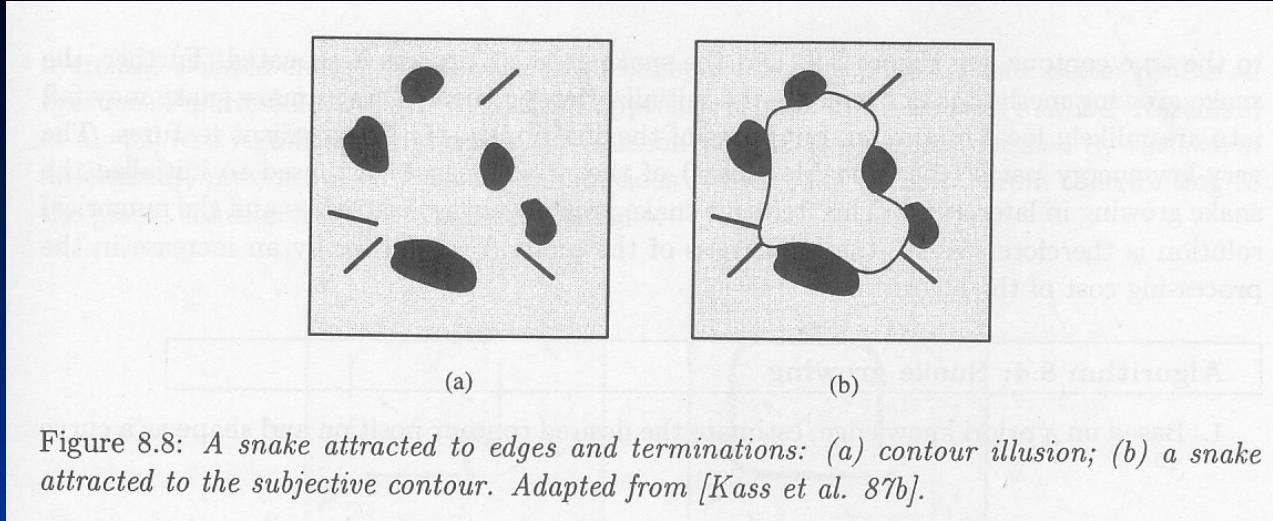
$s$  je z  $[0,1]$ .

- Minimalizovaná energia sa dá napísat' ako

$$E_{hada}^* = \int_0^1 E_{hada}(\mathbf{v}(s)) ds = \int_0^1 \{ [E_{\text{int}}(\mathbf{v}(s))] + [E_{\text{obraz}}(\mathbf{v}(s))] + [E_{\text{con}}(\mathbf{v}(s))] \} ds$$

- kde  $E_{\text{int}}$  reprezentuje vnútornú energiu splajnu vzhľadom na ohýbanie (obsahuje parametre ako elasticitu a tvrdosť),
- $E_{\text{obraz}}$  reprezentuje sily obrazu (obsahuje parametre, ktoré tiahajú hada k líniám, hranám a zakončeniam) a
- $E_{\text{con}}$  reprezentuje vonkajšie ohraničujúce sily (napr. apriórna znalosť z vyššieho procesu).

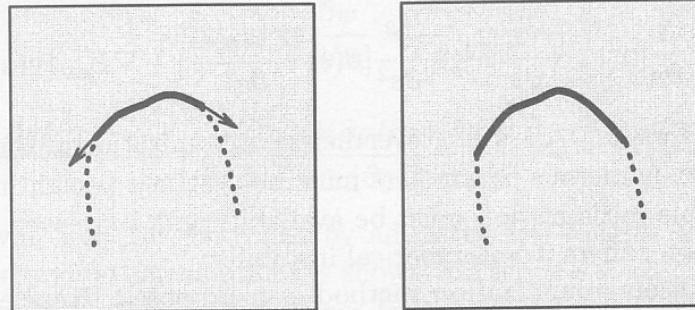
$$E_{\text{int}} = \alpha(s) \left| \frac{d\mathbf{v}}{ds} \right|^2 + \beta(s) \left| \frac{d^2\mathbf{v}}{ds^2} \right|^2$$



- Z Eulerovo-Lagrangeových podmienok vyplýva, že splajn, ktorý minimalizuje energiu, musí spĺňať

$$\frac{d}{ds} E_{\mathbf{v}_s} - E_{\mathbf{v}} = 0$$

kde  $E_{\mathbf{v}_s}$  je parciálna derivácia  $E$  vzhľadom na  $d\mathbf{v}/ds$  a  $E_{\mathbf{v}}$  je parciálna derivácia  $E$  vzhľadom na  $\mathbf{v}$ . Rovnica sa zväčša rieši numericky.

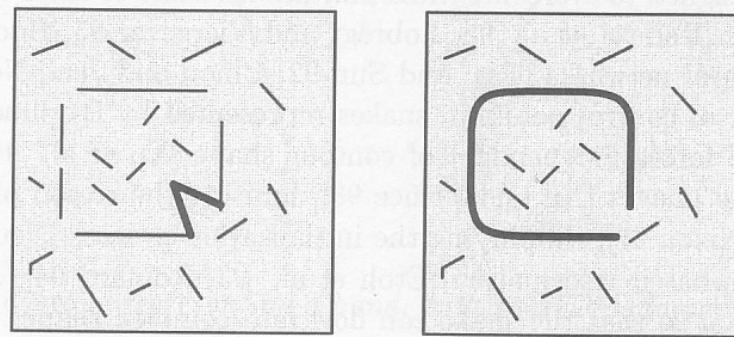


(a)

(b)

Figure 8.9: *Snake growing*: (a) lengthening in tangent direction; (b) energy minimization after a growing step.

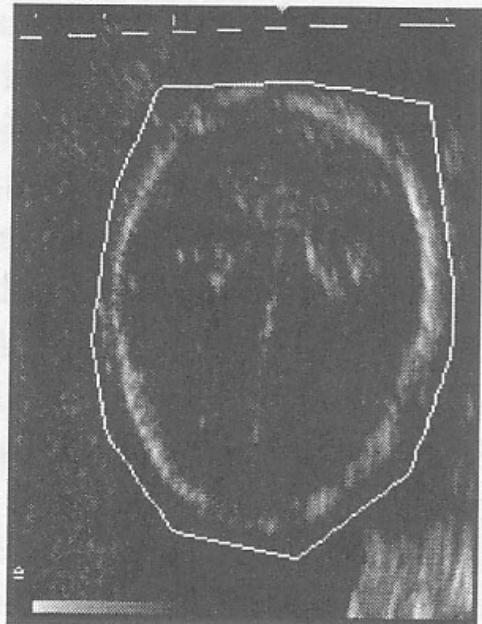
- Iný koncept pridáva ešte jednu energiu do vnútorných síl, ked' pozerá na krivku ako na balón, ktorý sa nafukuje. To umožňuje hadovi prekonat' izolované energetické doliny, pričom to dáva lepšie výsledky.



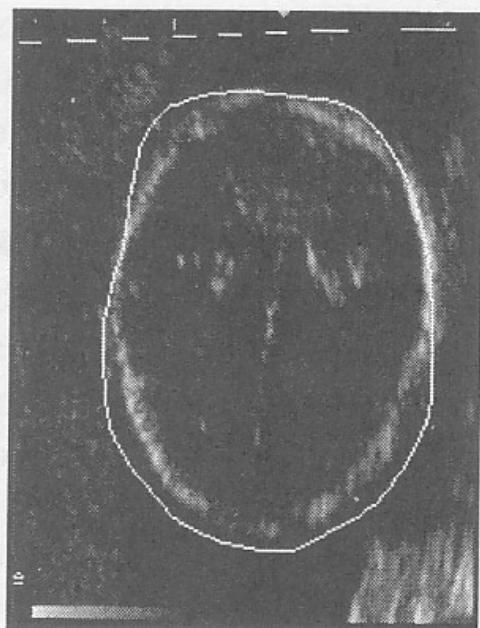
(a)

(b)

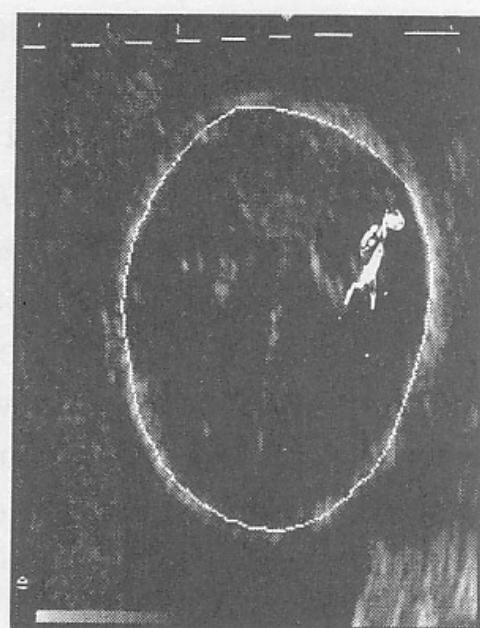
Figure 8.10: *Active contour model—balloon*: (a) initial contour; (b) final contour after inflation and energy minimization. Adapted from [Cohen and Cohen 92].



(a)



(b)



(c)

Figure 8.11: *B* alloon-based image segmentation of an ultrasound image of a fetal head: (a) initial position of the balloon; (b) balloon deformation after 10 iterations, (c) final position of the balloon after 25 iterations. Courtesy V. Chalana, MathSoft, Seattle, WA.